BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ TP. HCM

ĐỒ ÁN CƠ SỞ

NHẬN DIỆN UNG THƯ DA BẰNG PHƯƠNG PHÁP HỌC SÂU

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **MÁY HỌC & ỨNG DỤNG**

Giảng viên hướng dẫn : TS. Bùi Danh Hường

Sinh viên thực hiện : Ngô Hoàng Gia Bảo MSSV: 2280600198

Nguyễn Quốc Vương 2280603770

Huỳnh Minh Quân 2280602576

Lớp: 22DTHD3

TP. Hồ Chí Minh, ngày…, tháng…, năm 2025

MỤC LỤC

MỤC LỤC 1
DANH MỤC BẢNG BIỂU 2
DANH MỤC CÁC TỪ VIẾT TẮT 3
LỜI CẢM ƠN 4
MỞ ĐẦU 5
TỔNG QUAN TÌNH HÌNH NGHIÊN CỨU 7
LÝ DO CHỌN ĐỀ TÀI 9
MỤC TIÊU, NỘI DUNG & PHƯƠNG PHÁP NGHIÊN CỨU 10
I. Mục Tiêu: 10
II. Nội Dung: 10
III. Phương Pháp Nghiên Cứu: 11
ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU 13
KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN 14
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT 14
1.1 Học sâu (Deep Learning) và ứng dụng trong chẩn đoán y khoa 14
1.2 Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) 14
1.3 Bộ biến đổi thị giác (Vision Transformer – ViT) 15
1.4 Các chỉ số đánh giá mô hình học sâu 15
1.5 SMOTE – Synthetic Minority Over-sampling Technique: 16
CHƯƠNG 2: THIẾT KẾ MÔ HÌNH 18
1. Tổng quan về mô hình Hybrid CNN-ViT: 18
2. Triển khai mô hình: 19
2.1 Tiền xử lí dữ liệu đầu vào 19
2.2 Tách tập train và test 21
2.3 Kết hợp đặc trưng và huấn luyện mô hình lai CNN-ViT 21
CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ 31
KẾT LUẬN VÀ KIẾN NGHỊ 40
TÀI LIỆU THAM KHẢO 44
PHỤ LỤC 48

DANH MỤC BẢNG BIỂU

Danh mục hình ảnh:

Hình 1 Cấu trúc mô hình Hybrid CNN-ViT 19
Hình 2 ROC Curve & AUC của Hybrid trước SMOTE 34
Hình 3 ROC Curve & AUC của Hybrid sau SMOTE 35

Danh mục bảng:

Bảng 1 Chỉ số chi tiết của mô hình Hybrid trước và sau khi áp dụng SMOTE 35
Bảng 2 Chỉ số của mô hình Hybrid và các mô hình đối chứng trước và sau SMOTE 36
Bảng 3 Chỉ số class report của các mô hình trên tập PAD, kèm đánh giá cơ bản 38

DANH MỤC CÁC TỪ VIẾT TẮT

- AUC (Area Under the Curve): Diện tích dưới đường cong ROC, thể hiện khả năng phân biệt giữa hai lớp.
- BCE (Binary Cross Entropy): Hàm mất mát dùng trong phân loại nhị phân.
- CA (Cross Attention): Cơ chế chú ý chéo giữa hai loại đặc trưng (ví dụ: ảnh và metadata).
- CNN (Convolutional Neural Network): Mạng nơ-ron tích chập, dùng để trích xuất đặc trưng cục bộ từ ảnh.
- CLS (Class Token): Token đặc biệt trong ViT, đại diện cho toàn bộ ảnh đầu vào.
- FN (False Negative): Dự đoán sai âm tính – bỏ sót ca bệnh.
- FP (False Positive): Dự đoán sai dương tính – cảnh báo nhầm.
- F1-score: Trung bình điều hòa giữa độ chính xác (precision) và độ nhạy (recall).
- MHSA (Multi-head Self Attention): Cơ chế tự chú ý nhiều đầu trong Transformer.
- MLP (Multi-layer Perceptron): Mạng perceptron nhiều tầng, thường dùng sau attention.
- ReLU (Rectified Linear Unit): Hàm kích hoạt loại bỏ giá trị âm, giữ nguyên giá trị dương.
- ROC (Receiver Operating Characteristic): Đường cong đánh giá khả năng phân loại của mô hình.
- SE (Squeeze-and-Excitation): Cơ chế tăng cường thông tin kênh trong CNN.
- SMOTE (Synthetic Minority Over-sampling Technique): Kỹ thuật tăng cường mẫu lớp thiểu số.
- TN (True Negative): Dự đoán đúng ca không mắc bệnh.
- TP (True Positive): Dự đoán đúng ca mắc bệnh.
- ViT (Vision Transformer): Mô hình học sâu dựa trên Transformer, áp dụng trong xử lý ảnh.
- z-score (Standard score): Điểm chuẩn hóa giá trị theo phân phối chuẩn.

LỜI CẢM ƠN

Chúng em xin chân thành cảm ơn Giảng viên Tiến sĩ Bùi Danh Hường, người đã tận tình hướng dẫn và cung cấp những kiến thức quý báu trong suốt quá trình thực hiện đề tài "Nhận diện ung thư da bằng phương pháp học sâu". Thầy đã luôn nhiệt tình hỗ trợ chúng em trong suốt quá trình nghiên cứu và giúp chúng em hoàn thiện bài báo cáo này một cách tốt nhất. Những chỉ dẫn và lời khuyên của thầy không chỉ giúp chúng em hiểu rõ hơn về lĩnh vực học máy, học sâu và trí tuệ nhân tạo trong y tế mà còn giúp chúng em rèn luyện khả năng nghiên cứu độc lập và sáng tạo.

Chúng em cũng xin gửi lời cảm ơn đến các bạn đồng nghiệp và bạn bè tại trường HUTECH, những người đã luôn tạo ra một môi trường học tập sôi nổi và hỗ trợ chúng em rất nhiều trong quá trình thực hiện đề tài. Sự đồng hành và tinh thần hợp tác của các bạn đã giúp chúng em vượt qua những khó khăn trong quá trình học tập.

Cuối cùng, chúng em xin cảm ơn gia đình và những người thân yêu của chúng em, những người đã luôn bên cạnh, ủng hộ và động viên chúng em trong suốt thời gian qua. Sự yêu thương và sự hỗ trợ của gia đình là động lực lớn lao để chúng em có thể hoàn thành tốt công việc học tập và nghiên cứu.

Chúng em xin cam đoan rằng toàn bộ nội dung bài báo cáo này là kết quả nghiên cứu và làm việc độc lập của các thành viên nhóm chúng em. Mọi thông tin, dữ liệu và tài liệu được sử dụng trong báo cáo đều có nguồn gốc rõ ràng và được trích dẫn đầy đủ. Chúng em cam kết không sao chép, đạo nhái hay sử dụng bất kỳ nội dung nào không phải do mình thực hiện.

MỞ ĐẦU

Ung thư da là một trong những loại ung thư phổ biến nhất trên toàn cầu, với số ca mắc mới liên tục gia tăng trong những thập kỷ gần đây, đặc biệt tại các quốc gia có mức độ tiếp xúc với tia cực tím cao. Trong các dạng ung thư da, u hắc tố ác tính (melanoma) được xem là nguy hiểm nhất do đặc tính phát triển nhanh, dễ di căn và có tỷ lệ tử vong cao nếu không được phát hiện và điều trị kịp thời. Phát hiện sớm tổn thương ác tính đóng vai trò then chốt trong việc cải thiện tiên lượng và tăng khả năng sống sót cho bệnh nhân.

Tuy nhiên, phương pháp chẩn đoán truyền thống hiện nay chủ yếu dựa vào quan sát trực quan của bác sĩ da liễu, với sự hỗ trợ của thiết bị soi da (dermoscopy), vẫn còn tồn tại nhiều hạn chế. Độ chính xác trong đánh giá bằng mắt thường chỉ dao động từ 75–84%, phụ thuộc nhiều vào kinh nghiệm, kỹ năng chuyên môn của bác sĩ và khả năng tiếp cận cơ sở y tế chuyên khoa của bệnh nhân. Điều này đặc biệt đáng lo ngại tại các khu vực thiếu nguồn lực y tế hoặc dân cư sống rải rác.

Trước thực trạng đó, sự phát triển mạnh mẽ của trí tuệ nhân tạo (AI), đặc biệt là các phương pháp học sâu (deep learning), đã mở ra nhiều triển vọng mới trong việc xây dựng các hệ thống hỗ trợ chẩn đoán bằng máy tính (Computer-Aided Diagnosis – CAD). Trong lĩnh vực nhận diện tổn thương da, các mô hình học sâu như mạng nơ-ron tích chập (Convolutional Neural Networks – CNN) đã chứng minh hiệu quả vượt trội trong việc trích xuất đặc trưng hình ảnh và phân loại các tổn thương. Gần đây, mô hình bộ biến đổi thị giác (Vision Transformer – ViT), lấy cảm hứng từ kiến trúc Transformer trong xử lý ngôn ngữ tự nhiên, đã được ứng dụng vào thị giác máy tính với khả năng nắm bắt mối quan hệ toàn cục giữa các vùng ảnh. Sự kết hợp giữa CNN và ViT trong một mô hình lai (Hybrid CNN-ViT) hứa hẹn khai thác đồng thời đặc trưng cục bộ và toàn cục, từ đó nâng cao độ chính xác trong nhận diện tổn thương da.

Tuy nhiên, một thách thức lớn trong việc huấn luyện các mô hình học sâu là tình trạng mất cân bằng lớp dữ liệu. Trong các bộ dữ liệu công khai như ISIC2024, tỷ lệ ảnh gán nhãn u hắc tố ác tính thường rất thấp (khoảng 0.1%), khiến mô hình dễ thiên lệch về lớp lành tính và bỏ sót những trường hợp nguy hiểm. Để khắc phục vấn đề này, kỹ thuật SMOTE

(Synthetic Minority Over-sampling Technique) đã được sử dụng nhằm tạo ra các mẫu tổng hợp cho lớp thiểu số, giúp cải thiện hiệu quả học và phân loại của mô hình.

Trong nghiên cứu này, chúng tôi đề xuất một phương pháp nhận diện ung thư da dựa trên mô hình học sâu lai kết hợp CNN và ViT, đồng thời áp dụng SMOTE để cân bằng dữ liệu. Mô hình được thiết kế nhằm tận dụng sức mạnh của CNN trong trích xuất đặc trưng cục bộ và khả năng của ViT trong nắm bắt thông tin toàn cục. Hệ thống được huấn luyện và đánh giá trên hai bộ dữ liệu công khai ISIC2024 và PAD-UFES-20 để kiểm chứng hiệu quả và khả năng tổng quát hóa. Kết quả thực nghiệm cho thấy mô hình đạt hiệu suất cao, vượt trội so với các phương pháp truyền thống và mô hình đơn lẻ, góp phần khẳng định tiềm năng ứng dụng học sâu trong hỗ trợ chẩn đoán ung thư da một cách chính xác, khách quan và khả thi trên quy mô lớn.

TỔNG QUAN TÌNH HÌNH NGHIÊN CỨU

Hiện nay, các phương pháp học sâu đã chứng minh hiệu quả vượt trội trong nhiệm vụ phân loại tổn thương da. Cụ thể, nhiều nghiên cứu trên bộ dữ liệu dermoscopy cho thấy các kiến trúc CNN phổ biến như InceptionV3 và ResNet50 đạt độ chính xác cao (lần lượt khoảng 89,6% và 90,9%), tương đương với trình độ chẩn đoán của bác sĩ da liễu. Điều này khẳng định khả năng học đặc trưng tự động của CNN trong việc phát hiện các đặc điểm vi mô trên ảnh tổn thương. Song song đó, các mô hình Transformer, đặc biệt là Vision Transformer (ViT), đã được thử nghiệm và cho kết quả nổi bật hơn. Nhờ cơ chế self-attention giúp học được mối quan hệ toàn cục trong ảnh, ViT đạt độ chính xác lên tới 96,15% trên bộ dữ liệu HAM10000, cho thấy tiềm năng mạnh mẽ trong lĩnh vực thị giác máy tính y sinh.

Trong những năm gần đây (2023–2025), kiến trúc Transformer tiếp tục được ứng dụng rộng rãi trong lĩnh vực y tế, đặc biệt trong các bài toán xử lý ảnh y học và hỗ trợ chẩn đoán tự động. Cơ chế self-attention giúp mô hình nắm bắt hiệu quả các mối liên hệ phức tạp trong ảnh, vượt trội hơn so với các phương pháp truyền thống. Nhiều mô hình biến thể của Transformer và các mô hình lai CNN–Transformer đã được đề xuất, ghi nhận hiệu suất xuất sắc trong nhận diện ung thư da. Ví dụ, mô hình SkinViT sử dụng cơ chế Outlooker Attention đạt độ chính xác 91,09% trên bộ dữ liệu ISIC2019; các biến thể ViT-L16, ViT-L32 cũng đạt hiệu suất trên 91%. Các mô hình lai hiện đại như MD-CNNFormer kết hợp CNN đa tỉ lệ với Swin Transformer đã đạt độ chính xác 98,72% cùng chỉ số Dice Coefficient 97,67% trên các bộ dữ liệu chuẩn như HAM10000 và ISBI 2016, minh chứng cho hiệu quả vượt trội trong phân loại và phân đoạn tổn thương da ác tính.

Tuy nhiên, quá trình huấn luyện các mô hình này vẫn gặp phải một thách thức đáng kể là tình trạng mất cân bằng dữ liệu. Trong các bộ dữ liệu da liễu như HAM10000 hay ISIC2024, số lượng ảnh thuộc lớp u hắc tố ác tính (melanoma) thường chiếm tỷ lệ rất nhỏ so với các lớp lành tính, dẫn đến hiện tượng thiên lệch trong quá trình học. Điều này khiến mô hình dễ đưa ra dự đoán lệch (biased prediction), làm giảm hiệu suất phân loại tổng thể. Để khắc phục, nhiều nghiên cứu đã áp dụng các kỹ thuật tăng cường dữ liệu, trong đó có

SMOTE (Synthetic Minority Over-sampling Technique) nhằm tạo thêm các mẫu giả lập cho lớp thiểu số. Một khảo sát thực nghiệm cho thấy khi áp dụng SMOTE, độ chính xác của mô hình CNN có thể tăng từ 91,45% lên tới 97,81%, chứng tỏ hiệu quả rõ rệt của kỹ thuật này trong việc cải thiện độ cân bằng và hiệu năng mô hình.

Bên cạnh đó, xu hướng kết hợp hai loại kiến trúc CNN và Transformer đang ngày càng thu hút sự quan tâm. Các mô hình lai như Hybrid CNN-ViT hoặc SkinSwinViT tận dụng đồng thời khả năng trích xuất đặc trưng cục bộ của CNN và khả năng học biểu diễn toàn cục của Transformer. Nghiên cứu SkinSwinViT đã đạt độ chính xác lên đến 97,88% và F1-score 97,79% trên bộ dữ liệu ISIC/HAM10000, cùng với giá trị AUC rất cao. Những kết quả này vượt trội so với các kiến trúc CNN đơn lẻ, cho thấy tiềm năng lớn của mô hình lai trong phân loại đa lớp tổn thương da, với sự hài hòa giữa đặc trưng cục bộ và toàn cục.

Từ cơ sở lý thuyết và thực nghiệm trên, nghiên cứu này lựa chọn hướng tiếp cận kết hợp mô hình học sâu lai CNN-ViT cùng kỹ thuật SMOTE. Mục tiêu là khai thác đồng thời sức mạnh trích xuất đặc trưng của CNN và khả năng chú ý toàn cục của ViT, đồng thời khắc phục vấn đề mất cân bằng dữ liệu thông qua tổng hợp mẫu cho lớp u ác tính. Sự kết hợp này được kỳ vọng sẽ nâng cao độ chính xác, tính ổn định và khả năng tổng quát của hệ thống phát hiện ung thư da, từ đó góp phần thúc đẩy ứng dụng học sâu vào thực tiễn lâm sàng một cách hiệu quả và bền vững.

LÝ DO CHỌN ĐỀ TÀI

Ung thư da là một trong những loại ung thư phổ biến và ngày càng gia tăng trên toàn cầu, với nguy cơ tử vong cao nếu không được phát hiện và điều trị kịp thời. Việc chẩn đoán sớm và chính xác đóng vai trò then chốt trong việc nâng cao hiệu quả điều trị và cải thiện chất lượng cuộc sống cho bệnh nhân.

Trong bối cảnh đó, trí tuệ nhân tạo, đặc biệt là các phương pháp học sâu, đã chứng minh khả năng vượt trội trong phân tích hình ảnh y học, giúp phát hiện tổn thương da một cách tự động, nhanh chóng và chính xác, góp phần hỗ trợ bác sĩ giảm tải và tăng cường hiệu quả chẩn đoán. Tuy nhiên, các nghiên cứu hiện nay vẫn tồn tại những hạn chế đáng kể, nhất là vấn đề mất cân bằng dữ liệu do số lượng mẫu u ác tính rất ít so với các lớp tổn thương khác, làm giảm độ chính xác và tính ổn định của mô hình. Bên cạnh đó, các mô hình CNN thuần túy chưa khai thác triệt để mối quan hệ toàn cục trong ảnh, trong khi mô hình Transformer dù tiềm năng nhưng cần được kết hợp với CNN để tận dụng ưu điểm của cả hai kiến trúc.

Trước thực trạng đó, đề tài được lựa chọn nhằm phát triển một mô hình nhận diện ung thư da sử dụng kết hợp CNN và ViT, đồng thời tích hợp kỹ thuật SMOTE để xử lý dữ liệu mất cân bằng. Mô hình được kỳ vọng không chỉ đạt độ chính xác cao mà còn nâng cao khả năng nhận diện chính xác các tổn thương ác tính hiếm gặp, góp phần ứng dụng hiệu quả trí tuệ nhân tạo trong hỗ trợ chẩn đoán hình ảnh y học. Đề tài không chỉ đóng góp vào sự phát triển của khoa học công nghệ trong lĩnh vực y sinh mà còn có ý nghĩa thực tiễn quan trọng trong việc hỗ trợ công tác chẩn đoán, góp phần bảo vệ sức khỏe cộng đồng và giảm thiểu gánh nặng y tế toàn cầu.

MỤC TIÊU, NỘI DUNG & PHƯƠNG PHÁP NGHIÊN CỨU

I. Mục Tiêu:

Đề tài hướng đến việc xây dựng một mô hình học sâu có khả năng nhận diện tổn thương da, đặc biệt là các trường hợp ung thư da ác tính như u hắc tố (melanoma), với độ chính xác và khả năng khái quát hóa cao. Trong bối cảnh dữ liệu y tế thường bị mất cân bằng nghiêm trọng giữa các lớp lành tính và ác tính, mục tiêu của nghiên cứu là thiết kế một kiến trúc mạng lai kết hợp giữa mạng nơ-ron tích chập CNN và bộ biến đổi thị giác ViT, tận dụng đồng thời ưu điểm của việc trích xuất đặc trưng cục bộ từ CNN và khả năng học thông tin toàn cục từ ViT. Bên cạnh đó, đề tài tích hợp kỹ thuật tổng hợp dữ liệu thiểu số SMOTE nhằm khắc phục hiện tượng lệch nhãn và cải thiện khả năng nhận diện các tổn thương hiếm gặp nhưng nguy hiểm.

II. Nội Dung:

Đề tài này nghiên cứu phát triển một hệ thống chẩn đoán ung thư da dựa trên các kỹ thuật học sâu, bao gồm Mạng Nơ-ron Tích Chập (CNN) và Bộ Biến đổi Thị giác (ViT). Mục tiêu của nghiên cứu là xây dựng một mô hình có khả năng nhận diện ung thư da từ hình ảnh y tế, sử dụng các phương pháp tiên tiến để nâng cao độ chính xác và tính ổn định trong việc phân loại các hình ảnh ung thư da. Ngoài ra, đề tài cũng áp dụng các kỹ thuật xử lý dữ liệu mất cân bằng như SMOTE nhằm cải thiện hiệu suất mô hình trong việc phân loại các trường hợp hiếm gặp.

Phần cơ sở lý thuyết của nghiên cứu tập trung vào các phương pháp học sâu, đặc biệt là các mô hình CNN và ViT. CNN, với khả năng trích xuất đặc trưng không gian từ hình ảnh, được sử dụng để nhận diện và phân loại các đặc trưng quan trọng của ung thư da. Trong khi đó, ViT, thông qua cơ chế chuyển đổi không gian của các hình ảnh, giúp mô hình cải thiện khả năng xử lý các đặc trưng phức tạp, hỗ trợ phân loại chính xác hơn các mẫu ung thư da. Việc kết hợp CNN và ViT trong mô hình lai CNN–ViT giúp tận dụng những ưu điểm của cả hai phương pháp trong việc phân tích và nhận diện các đặc trưng hình ảnh.

Quá trình thực hiện nghiên cứu bao gồm các bước tiền xử lý dữ liệu, thiết kế kiến trúc mô hình, và huấn luyện mô hình. Các bước tiền xử lý bao gồm chuẩn hóa và tăng cường dữ liệu nhằm tăng tính đa dạng của bộ dữ liệu huấn luyện. Kiến trúc mô hình Hybrid CNN–ViT được xây dựng để kết hợp các lớp CNN với các lớp ViT, nhằm trích xuất đặc trưng hình ảnh hiệu quả hơn. Đặc biệt, kỹ thuật SMOTE được áp dụng để làm cân bằng bộ dữ liệu, nhằm cải thiện khả năng phân loại các lớp ít gặp trong bộ dữ liệu, từ đó giảm thiểu tình trạng mất cân bằng trong huấn luyện.

Trong quá trình huấn luyện, tốc độ học được điều chỉnh linh hoạt và các kỹ thuật ngừng sớm được áp dụng để tránh overfitting. Các chỉ số đánh giá hiệu suất như Accuracy, F1-score, AUC và pAUC được sử dụng để đánh giá hiệu quả của mô hình trên các bộ dữ liệu ISIC 2024 và PAD-UFES-20, nhằm đo lường khả năng phân loại ung thư da của hệ thống trong các tình huống thực tế.

Kết quả thực nghiệm từ việc áp dụng mô hình Hybrid CNN–ViT sẽ được trình bày và phân tích, thông qua việc so sánh các chỉ số đánh giá với các mô hình hiện có. Phân tích này sẽ chỉ ra hiệu quả của việc kết hợp CNN và ViT trong việc nâng cao khả năng nhận diện ung thư da, đồng thời đánh giá tác động của kỹ thuật SMOTE trong việc giải quyết vấn đề mất cân bằng dữ liệu.

Cuối cùng, nghiên cứu sẽ tổng kết những kết quả đạt được, nêu rõ những đóng góp của đề tài trong việc phát triển các công nghệ hỗ trợ chẩn đoán ung thư da. Đồng thời, nghiên cứu sẽ đề xuất các hướng phát triển trong tương lai, bao gồm cải tiến mô hình, mở rộng thử nghiệm trên các bộ dữ liệu thực tế, và tích hợp hệ thống vào các nền tảng hỗ trợ chẩn đoán lâm sàng

III. Phương Pháp Nghiên Cứu:

Để giải quyết bài toán nhận diện ung thư da, đặc biệt là u hắc tố ác tính (melanoma), nghiên cứu này đề xuất mô hình học sâu lai mang tên Hybrid CNN-ViT, kết hợp giữa EfficientNet-B0 và bộ biến đổi thị giác ViT-B/16. Mục tiêu là tận dụng hiệu quả khả năng trích xuất đặc trưng cục bộ của CNN và khả năng học biểu diễn toàn cục của Transformer, nhằm nâng cao hiệu suất nhận diện tổn thương ác tính trên ảnh da liễu.

Về kiến trúc, mô hình được chia thành hai khối chính: (1) khối xử lý đặc trưng và (2) khối phân loại. Trong khối đầu tiên, ảnh đầu vào được chuẩn hóa và resize về kích thước 224×224 pixel. EfficientNet-B0 sẽ trích xuất các đặc trưng cục bộ từ ảnh, tạo ra một biểu diễn có kích thước 1×512. Biểu diễn này sau đó được đưa vào ViT-B/16, gồm 12 encoder blocks với 12 attention heads mỗi block và embedding size là 768, giúp học các quan hệ toàn cục giữa các vùng ảnh. Các đặc trưng từ hai nhánh được nối (concatenate) và chuyển qua chuỗi các lớp Fully Connected gồm Batch Normalization, ReLU, Dropout (0.5) và Dense layer để tối ưu hóa biểu diễn đặc trưng.

Quá trình tiền xử lý dữ liệu bao gồm: (1) chuẩn hóa ảnh và metadata, (2) áp dụng kỹ thuật tăng cường dữ liệu (augmentation) nhằm đa dạng hóa mẫu, và (3) sử dụng SMOTE (Synthetic Minority Over-sampling Technique) để giải quyết mất cân bằng dữ liệu, đặc biệt đối với lớp melanoma vốn chiếm tỷ lệ thấp. Thêm vào đó, quá trình feature engineering được thực hiện bằng cách kết hợp thông tin từ ảnh và metadata để tăng cường khả năng học của mô hình.

Mô hình được huấn luyện trên tập dữ liệu ISIC với hàm mất mát CrossEntropy có trọng số lớp, tối ưu bằng thuật toán AdamW. Đánh giá hiệu suất mô hình dựa trên các chỉ số chính: Confusion Matrix, AUC và pAUC, đảm bảo phản ánh toàn diện khả năng phân loại của hệ thống, đặc biệt trong bối cảnh dữ liệu bất cân bằng.

Sự kết hợp giữa các thành phần CNN, ViT và kỹ thuật xử lý dữ liệu tiên tiến được kỳ vọng mang lại một hệ thống chẩn đoán ung thư da hiệu quả, có tính ứng dụng cao trong thực tiễn lâm sàng.

ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

Đối tượng nghiên cứu của đề tài là hình ảnh tổn thương da được thu thập từ hai cơ sở dữ liệu công khai: ISIC2024 và PAD-UFES-20. Bộ dữ liệu ISIC2024 bao gồm 401.059 ảnh, trong đó chỉ có 393 ảnh là ác tính, còn lại là ảnh lành tính. Từ đó, một tập con được xây dựng để huấn luyện mô hình, bao gồm 29.868 ảnh (393 ảnh ác tính và 29.475 ảnh lành tính được chọn ngẫu nhiên) nhằm phản ánh sự mất cân bằng trong thực tế. Bên cạnh đó, bộ dữ liệu PAD-UFES-20 cung cấp 2.298 ảnh thu thập trong môi trường lâm sàng thực, với phân bố lớp tương đối cân bằng và metadata đầy đủ (tuổi, giới tính, vị trí tổn thương), góp phần tăng tính đa dạng và khả năng tổng quát hóa cho mô hình.

Phạm vi nghiên cứu tập trung vào việc xây dựng, huấn luyện và đánh giá mô hình học sâu lai (Hybrid CNN-ViT), kết hợp giữa EfficientNet-B0 và ViT-B/16, cùng với kỹ thuật SMOTE để xử lý mất cân bằng dữ liệu. Các ảnh đầu vào là ảnh tĩnh chụp từ thiết bị dermoscopy, kết hợp với metadata cơ bản. Nghiên cứu không xem xét các loại dữ liệu chuyên sâu như tiền sử bệnh, thông tin gen hay kết quả sinh thiết.

Các thí nghiệm được thực hiện trên máy tính cá nhân với CPU Intel Core i5-11450H, RAM 16GB, và GPU NVIDIA RTX 4050. Hệ thống phần mềm sử dụng bao gồm Python 3.11, PyTorch 2.0, scikit-learn 1.2.2, pandas 2.0.0 và matplotlib 3.7.1, triển khai trong môi trường Visual Studio Code tích hợp Jupyter Notebook.

Mô hình được đánh giá trong môi trường tính toán mô phỏng (offline), chưa triển khai trong thực tiễn lâm sàng. Tuy nhiên, kết quả nghiên cứu có tiềm năng ứng dụng trong các hệ thống hỗ trợ chẩn đoán tổn thương da, đặc biệt tại những khu vực thiếu bác sĩ da liễu hoặc trang thiết bị hiện đại.

KẾT QUẢ NGHIÊN CỨU VÀ THẢO LUẬN

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT

1.1 Học sâu (Deep Learning) và ứng dụng trong chẩn đoán y khoa

Học sâu là một lĩnh vực con của học máy (Machine Learning), nơi các mô hình được xây dựng từ mạng nơ-ron nhân tạo với nhiều tầng, có khả năng học biểu diễn dữ liệu ở nhiều mức trừu tượng khác nhau (LeCun et al., 2015). So với các phương pháp học máy truyền thống yêu cầu trích xuất đặc trưng thủ công, học sâu cho phép mô hình tự học các đặc trưng từ dữ liệu thô, đặc biệt hiệu quả với dữ liệu hình ảnh.

Trong y học, học sâu đang ngày càng đóng vai trò quan trọng, đặc biệt trong chẩn đoán hình ảnh y khoa như: X-quang, MRI, CT scan, và ảnh chụp da (Esteva et al., 2017). Các mô hình học sâu không chỉ giúp giảm tải cho bác sĩ mà còn hỗ trợ phát hiện sớm các dấu hiệu bất thường, chẳng hạn như u hắc tố (melanoma), một loại ung thư da nguy hiểm.

1.2 Mạng nơ-ron tích chập (Convolutional Neural Network – CNN)

CNN là một loại mạng nơ-ron được thiết kế chuyên biệt để xử lý dữ liệu có cấu trúc dạng lưới như hình ảnh (Krizhevsky et al., 2012). Các thành phần chính của CNN gồm:

- Lớp tích chập (Convolutional Layer): Trích xuất các đặc trưng cục bộ như cạnh, góc, vết nám, đốm bất thường.
- Lớp kích hoạt (Activation Function, thường dùng ReLU): Tăng tính phi tuyến cho mô hình.
- Lớp gộp (Pooling Layer): Giảm chiều dữ liệu và tăng tính khái quát.
- Lớp fully connected (Dense Layer): Đưa đặc trưng vào quá trình phân loại.

Trong nghiên cứu này, EfficientNet-B0 được lựa chọn vì khả năng cân bằng hiệu quả giữa độ chính xác và chi phí tính toán nhờ thiết kế tối ưu hóa tự động (Tan & Le, 2019). Mạng sử dụng các khối MBConv (Mobile Inverted Bottleneck Convolution) kết hợp với cơ chế Squeeze-and-Excitation (SE) để tăng cường khả năng học trọng số kênh, giúp mô hình trích xuất đặc trưng hiệu quả từ ảnh tổn thương da. Mặc dù không sử dụng cấu trúc residual truyền thống như ResNet34, EfficientNet-B0 vẫn duy trì khả năng truyền thông tin và

gradient tốt nhờ thiết kế bottleneck đảo chiều (inverted residuals). Nhờ đó, mô hình có thể học các đặc trưng phức tạp trong ảnh da mà vẫn đảm bảo tốc độ và khả năng hội tụ khi huấn luyện.

1.3 Bộ biến đổi thị giác (Vision Transformer – ViT)

ViT là kiến trúc xử lý ảnh dựa trên cơ chế Attention thay vì tích chập như CNN (Dosovitskiy et al., 2020). Ý tưởng của ViT là chia ảnh thành các ô vuông nhỏ (patches), biến chúng thành vector và xử lý chúng như chuỗi dữ liệu, tương tự như xử lý ngôn ngữ tự nhiên trong Transformer.

ViT gồm các thành phần chính:

- Patch Embedding: Chia ảnh thành các patch (ví dụ 16×16), biến chúng thành vector.
- Position Embedding: Bổ sung thông tin vị trí cho các patch.
- Encoder Blocks: Mỗi block gồm Multi-Head Self Attention và Feed Forward Network, giúp mô hình học mối liên hệ toàn cục.
- Classification Head: Tính toán xác suất đầu ra cho mỗi lớp.

ViT vượt trội trong việc nắm bắt mối quan hệ toàn ảnh, bổ sung cho khả năng học đặc trưng cục bộ của CNN. Trong nghiên cứu này, mô hình ViT-B/16 được sử dụng, với 12 encoder blocks, mỗi block gồm 12 heads và kích thước embedding là 768, cho phép mô hình học thông tin sâu và toàn diện hơn từ ảnh da.

1.4 Các chỉ số đánh giá mô hình học sâu

Đánh giá một mô hình phân loại, đặc biệt trong lĩnh vực y tế, không chỉ dựa vào độ chính xác tổng thể mà cần xem xét nhiều khía cạnh khác để đảm bảo mô hình không bỏ sót các ca bệnh nghiêm trọng (Saito & Rehmsmeier, 2015). Các chỉ số quan trọng bao gồm:

- **ROC AUC và Raw/Normalized pAUC (với ngưỡng FPR ≤ 0.1 và 0.2):** ROC AUC (Area Under the Receiver Operating Characteristic Curve) thể hiện năng lực phân biệt giữa hai lớp. Giá trị AUC gần 1.0 cho thấy mô hình có khả năng phân biệt tốt giữa ca bệnh và không bệnh. Trong khi đó, pAUC (partial AUC) là phần diện tích AUC tập trung vào vùng FPR nhỏ (tức tỷ lệ dương tính giả thấp), phản ánh hiệu suất mô hình trong điều kiện yêu cầu độ nhạy cao. Trong y học, pAUC đặc biệt

quan trọng vì các bác sĩ ưu tiên mô hình phát hiện đúng nhiều ca bệnh (recall cao), trong khi vẫn giữ FPR ở mức chấp nhận được.

- **Confusion Matrix:**
  Là ma trận thể hiện tổng quan kết quả phân loại theo 4 nhóm: True Positive (TP), False Positive (FP), True Negative (TN), và False Negative (FN). Ma trận này giúp đánh giá trực quan mô hình có thiên lệch lớp hay không, cũng như khả năng phát hiện đúng ca bệnh so với ca không bệnh. Đặc biệt, số lượng FN (ca bệnh bị bỏ sót) là chỉ số nhạy cảm và cần giảm thiểu trong các ứng dụng y tế.

1.5 SMOTE – Synthetic Minority Over-sampling Technique:

SMOTE (Synthetic Minority Over-sampling Technique) là một kỹ thuật xử lý mất cân bằng dữ liệu trong học máy, được đề xuất bởi Chawla et al. vào năm 2002 (Chawla et al, 2002). Phương pháp này nhằm tăng số lượng mẫu thuộc lớp thiểu số bằng cách sinh ra các điểm dữ liệu tổng hợp (synthetic samples) thay vì chỉ sao chép lại các điểm gốc như phương pháp oversampling truyền thống.

Mục tiêu của SMOTE:

Trong các bài toán phân loại có dữ liệu mất cân bằng nghiêm trọng – ví dụ như chẩn đoán ung thư, gian lận tài chính hoặc phát hiện lỗi – các thuật toán học máy thường có xu hướng thiên lệch về lớp đa số. Điều này dẫn đến việc bỏ sót các trường hợp quan trọng (false negatives) thuộc lớp thiểu số. SMOTE được thiết kế để giải quyết vấn đề này bằng cách mở rộng không gian đặc trưng của lớp thiểu số một cách có kiểm soát.

Nguyên lý hoạt động:

Với mỗi mẫu thuộc lớp thiểu số (được gọi là điểm gốc), SMOTE thực hiện các bước sau:

- Tìm k láng giềng gần nhất (thường là k=5) của điểm đó trong cùng lớp thiểu số.
- Ngẫu nhiên chọn một hoặc nhiều điểm trong số các láng giềng.
- Sinh điểm mới bằng cách nội suy (interpolation) giữa điểm gốc và điểm láng giềng được chọn:

$$\boldsymbol{x_{new}} = \boldsymbol{x_i} + \boldsymbol{\lambda}.(\boldsymbol{x_j} - \boldsymbol{x_i})$$

Kết quả là một điểm mới nằm trên đoạn thẳng nối giữa hai điểm trong không gian đặc trưng, giúp mở rộng không gian lớp thiểu số và tạo ra sự đa dạng trong dữ liệu.

Ưu điểm:

- Giảm hiện tượng overfitting do không chỉ sao chép lại mẫu.
- Cải thiện độ nhạy (Recall) và F1-score trong bài toán phân loại mất cân bằng.
- Dễ triển khai, có sẵn trong nhiều thư viện (scikit-learn, imbalanced-learn).

Hạn chế:

- Có thể sinh ra mẫu không hợp lệ trong không gian dữ liệu không tuyến tính hoặc có phân ranh rõ rệt.
- Không xử lý tốt khi lớp thiểu số có phân bố rải rác (sparse).
- Không tăng thêm thông tin, chỉ nội suy từ dữ liệu gốc.

CHƯƠNG 2: THIẾT KẾ MÔ HÌNH

1. Tổng quan về mô hình Hybrid CNN-ViT:

1.1 Mục tiêu thiết kế:

Mục tiêu chính của việc thiết kế mô hình là xây dựng một kiến trúc lai (hybrid model) kết hợp giữa hai phương pháp mạnh trong xử lý ảnh: CNN và Vision Transformer (ViT). CNN có khả năng trích xuất đặc trưng cục bộ hiệu quả, trong khi ViT có thể nắm bắt thông tin toàn cục nhờ cơ chế tự chú ý (self-attention). Việc kết hợp hai mô hình nhằm tận dụng ưu điểm của cả hai để nâng cao hiệu quả phân loại hình ảnh tổn thương da, đặc biệt trong điều kiện dữ liệu mất cân bằng và đa dạng về hình thái tổn thương.

1.2 Kiến trúc tổng thể của mô hình Hybrid CNN-ViT:

Mô hình được xây dựng gồm ba thành phần chính:

- Backbone CNN: Sử dụng EfficientNet-B0 để trích xuất đặc trưng cục bộ từ ảnh đầu vào.
- Module ViT: Nhận đầu vào là đặc trưng trích xuất từ CNN và xử lý thông qua các lớp Transformer encoder.
- Head phân loại: Một mạng fully connected kết hợp Dropout để đưa ra kết quả phân loại lành tính hoặc ác tính.

1.3 Kỹ thuật bổ trợ:

1.3.1 Cân bằng dữ liệu bằng SMOTE

- Áp dụng Synthetic Minority Over-sampling Technique (SMOTE) sau khi trích xuất đặc trưng từ ảnh để tạo thêm mẫu dữ liệu ác tính.
- Tăng độ cân bằng lớp, giúp mô hình không bị thiên lệch.

1.3.2 Chuẩn hóa và tiền xử lý ảnh

- Kích thước ảnh đầu vào: 224×224
- Normalization theo chuẩn ImageNet
- Data Augmentation: RandomFlip, ColorJitter, Rotation, CenterCrop để tăng độ đa dạng ảnh

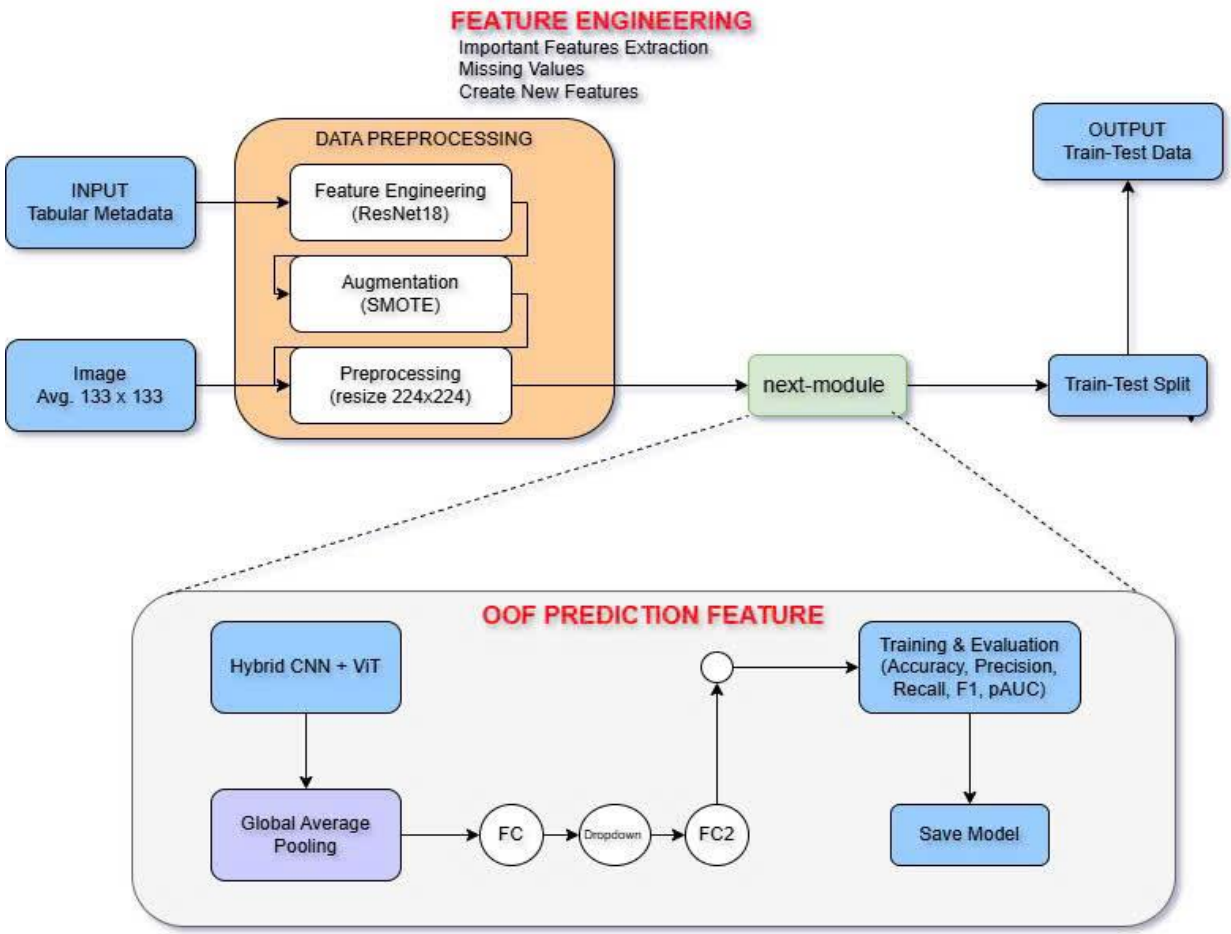

Hình 1. Cấu trúc mô hình Hybrid CNN-ViT

2. Triển khai mô hình:

2.1 Tiền xử lí dữ liệu đầu vào

Trong nghiên cứu này, dữ liệu đầu vào bao gồm hai thành phần chính: dữ liệu hình ảnh da liễu và metadata dạng bảng (tabular metadata). Mỗi thành phần được xử lý theo những bước riêng biệt nhằm chuẩn hóa, tăng cường và trích xuất đặc trưng, từ đó nâng cao hiệu quả huấn luyện và độ chính xác của mô hình phân loại ung thư da.

Xử lý dữ liệu hình ảnh

Hình ảnh đầu vào từ các bộ dữ liệu ISIC2024 và PAD-UFES-20 có kích thước và chất lượng không đồng đều, với kích thước trung bình khoảng 133×133 pixel. Để đảm bảo

tương thích với kiến trúc mô hình học sâu, tất cả ảnh được resize về kích thước chuẩn 224×224 pixel. Sau đó, ảnh được chuẩn hóa giá trị pixel và chuyển về định dạng RGB.

Thay vì trực tiếp áp dụng kỹ thuật tăng cường trên ảnh thô, nghiên cứu này tiến hành trích xuất đặc trưng hình ảnh thông qua mô hình ResNet18, vốn được huấn luyện sơ bộ để thu được các đặc trưng sâu. Những đặc trưng này, ở dạng vector, sau đó được sử dụng làm đầu vào cho kỹ thuật SMOTE. Việc áp dụng SMOTE trên không gian đặc trưng hình ảnh - thay vì ảnh gốc hay metadata - cho phép mô hình sinh tổng hợp mẫu thiểu số một cách hợp lý và có ý nghĩa hơn, đồng thời duy trì tính nhất quán trong phân bố đặc trưng.

Xử lý metadata của bộ ISIC2024

Metadata dạng bảng trong ISIC2024 có cấu trúc phức tạp, bao gồm:

- 34 cột gốc dạng số học (NUM_COLS)
- 43 cột mới được sinh ra trong quá trình xử lý (NEW_NUM_COLS)
- 6 cột dạng danh mục (CAT_COLS), sau đó được mã hóa one-hot để thay thế các cột gốc
- 1 cột đặc biệt (SPECIAL_COLS) – count_per_patient
- 77 cột chuẩn hóa (NORM_COLS), được tạo bằng cách kết hợp và chuẩn hóa NUM_COLS và NEW_NUM_COLS
- 12 cột đặc trưng hình ảnh, được gán sau bước trích xuất đặc trưng
- 1 cột đầu ra dự đoán của mô hình

Tổng số đặc trưng đầu vào có thể vượt quá 161 cột, tùy thuộc vào số lượng danh mục xuất hiện trong các cột phân loại sau khi mã hóa.

Toàn bộ các đặc trưng này sau khi xử lý sẽ được kết hợp thành một ma trận đặc trưng tổng hợp (feature matrix) phục vụ cho quá trình huấn luyện mô hình. Giá trị thiếu được xử lý bằng các chiến lược nội suy hoặc loại bỏ. Các biến danh mục được xử lý bằng mã hóa one-hot để đảm bảo định dạng đầu vào phù hợp với mô hình học máy.

Xử lý metadata của bộ PAD-UFES-20

Metadata của PAD-UFES-20 đơn giản hơn và mang tính lâm sàng thực tế cao. Các đặc trưng chính bao gồm:

- Đặc trưng định lượng: age, diameter_1, diameter_2

- Triệu chứng lâm sàng (biến nhị phân): itch, grew, hurt, changed, bleed, elevation, biopsed
- Biến diagnostic chứa nhãn ban đầu, được ánh xạ về target theo quy tắc: các nhãn lành tính ('ACK', 'NEV', 'SEK') gán giá trị 0, các nhãn ác tính ('BCC', 'MEL', 'SCC', 'BOD') gán giá trị 1

Các giá trị được chuẩn hóa về cùng đơn vị. Sau khi xử lý, dữ liệu được đưa vào pipeline huấn luyện mô hình như một luồng đầu vào độc lập hoặc kết hợp với đặc trưng hình ảnh thông qua các tầng hợp nhất.

2.2 Tách tập train và test

Dữ liệu đã qua tiền xử lý sẽ được chia thành hai tập và có 80% tập huấn luyện và 20% là tập kiểm tra và validator(10% mỗi tập). Việc tách này đảm bảo đánh giá khách quan mô hình trên dữ liệu chưa từng thấy. Trong một số trường hợp, có thể sử dụng kỹ thuật Cross-validation hoặc OOF (Out-Of-Fold) để tăng độ tin cậy trong đánh giá.

2.3 Kết hợp đặc trưng và huấn luyện mô hình lai CNN-ViT

Đầu tiên, chúng tôi sẽ lấy đặc trưng từ ảnh trong tập huấn luyện sau khi đã tiền xử lí dữ liệu qua các block trong EfficientNet-B0:

2.2.1 Block 1: Conv2D, BatchNorm và SiLU (Swish)

Conv2D:

- Công thức:

$$\boldsymbol{Output_{i,j,k}} = \sum_{h=0}^{H-1}\sum_{w=0}^{W-1} \boldsymbol{Input_{i+h,j+w,k`}} . \boldsymbol{Kernel_{h,w,k`,k}} + \boldsymbol{Bias_k}$$

-Tác động của lớp đầu tiên trong mô hình này là nó có khả năng phát hiện các đường biên rõ ràng giữa vùng da lành và vùng tổn thương, từ đó giúp mô hình xác định ranh giới của khối u. Bên cạnh đó, nó còn nhận diện các thay đổi về màu sắc – một dấu hiệu quan trọng trong chẩn đoán ung thư da – như các vùng tăng sắc tố, đốm đen hoặc vùng bị mất sắc tố. Cuối cùng, lớp này có thể học được các đặc trưng về kết cấu bề mặt của da như mức độ gồ

ghề, sự hiện diện của vảy hoặc độ mịn, hỗ trợ mô hình phân biệt giữa tổn thương lành tính và ác tính ngay từ giai đoạn đầu xử lý ảnh.

BatchNorm:

- Công thức:

$$\boldsymbol{y = \gamma . \frac{x - \mu B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta}$$

Tác động lên dữ liệu tại lớp Batch Normalization là chuẩn hóa các giá trị kích hoạt đầu ra từ lớp Conv2D, đưa chúng về phân phối chuẩn với trung bình gần 0 và độ lệch chuẩn gần 1. Điều này giúp ổn định quá trình huấn luyện và tăng tốc độ hội tụ. Trong bối cảnh ảnh ung thư da, kỹ thuật này đặc biệt quan trọng vì dữ liệu thường có sự khác biệt đáng kể về ánh sáng, độ tương phản và điều kiện chụp – nhất là khi được thu thập từ nhiều nguồn bệnh viện hoặc thiết bị khác nhau. BatchNorm giúp làm giảm tác động tiêu cực từ những sai lệch này, đảm bảo rằng các đặc trưng học được không bị chi phối bởi sự không đồng nhất trong đầu vào, từ đó giúp mô hình học được những đặc trưng ổn định và tổng quát hơn.

SiLU (Swish)

- Công thức:

$$\boldsymbol{SiLU(x) = x.\sigma(x) = x.\frac{1}{1 + e^{-x}}}$$

Tác động lên dữ liệu tại lớp SiLU (Sigmoid Linear Unit) là áp dụng một hàm phi tuyến tính mềm, trong đó các giá trị dương lớn được giữ gần nguyên, còn các giá trị âm nhỏ không bị loại bỏ hoàn toàn mà chỉ bị làm giảm biên độ. Khác với ReLU – vốn loại bỏ hoàn toàn các giá trị âm – SiLU giữ lại một phần thông tin của các tín hiệu yếu, giúp mô hình học được nhiều đặc trưng tinh vi hơn. Với ảnh ung thư da, điều này cho phép mạng thần kinh phát hiện các bất thường nhẹ về màu sắc hoặc kết cấu mà ReLU có thể bỏ qua, từ đó tăng khả năng nhận diện chính xác các dấu hiệu tiềm ẩn của bệnh lý.

2.2.2 Block 2: MBConv (Depthwise Conv, SE, Pointwise Conv)

EfficientNet sử dụng khối MBConv làm đơn vị cơ bản.

Depthwise Convolution

- Công thức:

$$\boldsymbol{Output_{i,j,k}} = \sum_{h=0}^{H-1} \sum_{w=0}^{W-1} \boldsymbol{Input_{i+h,j+w,k}} . \boldsymbol{Kernel_{h,w,k}}$$

Tác động lên dữ liệu tại lớp Depthwise Convolution là thực hiện phép tích chập riêng biệt trên từng kênh đầu vào thay vì gộp lại như trong tích chập thông thường. Điều này giúp giảm đáng kể số lượng tham số và tính toán, đồng thời vẫn giữ nguyên cấu trúc không gian của đặc trưng. Trong trường hợp ảnh ung thư da, Depthwise Convolution cho phép mô hình khai thác hiệu quả thông tin trong từng kênh đặc trưng, như sự khác biệt tinh tế về màu sắc, kết cấu hoặc ranh giới tổn thương. Việc xử lý chuyên biệt theo kênh này giúp tăng khả năng phát hiện các biểu hiện bệnh lý đặc thù, trong khi vẫn đảm bảo hiệu suất cao và tránh dư thừa tính toán trong mạng nơ-ron.

Squeeze-and-Excitation (SE) Block

- Công thức:

- **Squeeze (GAP):**

$$\boldsymbol{z_k} = \frac{\boldsymbol{1}}{\boldsymbol{H} \times \boldsymbol{W}} \sum_{i=1}^{H} \sum_{j=1}^{W} \boldsymbol{X_{i,j,k}}$$

- **Excitation:**

$$\boldsymbol{s} = \boldsymbol{\sigma}(\boldsymbol{W_2} . \boldsymbol{ReLU}(\boldsymbol{W_1} . \boldsymbol{z}))$$

- **Scale:**

$$\widetilde{\boldsymbol{X}}_{\boldsymbol{k}} = \boldsymbol{X_k} . \boldsymbol{s_k}$$

Tác động lên dữ liệu của Squeeze-and-Excitation (SE) Block là làm nổi bật các kênh đặc trưng quan trọng bằng cách học cách phân bổ trọng số chú ý cho từng kênh. SE Block thực hiện điều này thông qua hai bước: "squeeze" (nén không gian) giúp tổng hợp thông tin toàn cục từ mỗi kênh, và "excitation" (kích hoạt) để tái điều chỉnh trọng số cho từng kênh dựa trên tầm quan trọng của chúng. Trong trường hợp ảnh ung thư da, cơ chế này cho phép mô hình tăng cường sự nhạy cảm với các đặc trưng quan trọng như đường viền bất thường,

vùng tăng sắc tố hoặc sự phân bố màu không đồng đều – những dấu hiệu quan trọng trong việc phân loại tổn thương lành hay ác tính. SE Block góp phần nâng cao khả năng tập trung vào thông tin có giá trị chẩn đoán cao và giảm ảnh hưởng của các đặc trưng không quan trọng, từ đó cải thiện độ chính xác của mô hình.

Pointwise Convolution (1×1 Conv)

Tác động: Kết hợp đặc trưng từ các kênh khác nhau, ví dụ: tổng hợp kết cấu và màu sắc của vùng tổn thương.

2.2.3 Block 3: MBConv với số kênh tăng (64 → 128)

Tác động:

Tại tầng này, MBConv (Mobile Inverted Bottleneck Convolution) bắt đầu phát huy khả năng trích xuất các đặc trưng trung cấp – những biểu hiện rõ ràng hơn nhưng vẫn chưa phải đặc trưng xác định bệnh.

Các thông tin mà mô hình có thể nhận diện bao gồm:

- **Cấu trúc mạch máu bất thường:** như dạng vòng, nhánh cây hoặc xoắn – thường xuất hiện trong các loại tổn thương tiền ung thư hoặc ung thư biểu mô.
- **Vùng thoái hóa sắc tố:** các vùng giảm sắc tố hoặc mất màu không đều gợi ý sự rối loạn cấu trúc mô dưới da.
- **Cấu trúc dots/globules (điểm và khối tròn nhỏ):** là những chấm sắc tố nhỏ có thể phân bố đều (lành tính) hoặc bất thường (ác tính).

Nhờ khả năng phát hiện và tổng hợp các đặc trưng trung gian này, tầng MBConv-128 giúp mô hình phân biệt hiệu quả hơn giữa các tổn thương lành tính và ác tính dựa trên các tín hiệu đặc trưng chưa rõ ràng nhưng có giá trị cảnh báo.

2.2.4 Block 4: MBConv với số kênh tăng (128 → 256)

Tác động:

Ở tầng này, mạng bắt đầu học các đặc trưng cấp cao, mang ý nghĩa lâm sàng rõ ràng và thường liên quan trực tiếp đến các biểu hiện cụ thể của bệnh ung thư da.

Một số đặc trưng có thể được mô hình hóa:

- **Blue-white veil (màng xanh trắng):** đặc trưng điển hình của melanoma ác tính, biểu hiện cho vùng tăng sinh tế bào sắc tố và tiêu biến lớp sừng.
- **Wheel structure (cấu trúc bánh xe):** thường thấy trong ung thư tế bào đáy (Basal Cell Carcinoma), với các tia sắc tố tỏa ra như nan hoa.
- **Sự phối hợp màu bất thường:** xuất hiện đồng thời các vùng màu đỏ, nâu, đen, xanh – biểu thị sự mất kiểm soát trong phân bố melanin, máu và mô hoại tử.

Tầng này đóng vai trò như một công cụ chẩn đoán lâm sàng tự động, giúp mô hình chú ý đến các biểu hiện đặc trưng nhất, cải thiện khả năng nhận diện tổn thương có độ nghi ngờ cao.

2.2.5 Block 5: MBConv với số kênh tăng (256 → 512)

Tác động:

Tầng cuối cùng trước khi chuyển sang các lớp phân loại, MBConv với 512 kênh có khả năng tổng hợp các đặc trưng trừu tượng cao nhất từ toàn bộ ảnh tổn thương.

Tại đây, mô hình có thể học và mô phỏng các yếu tố ABCDE – chuẩn đánh giá lâm sàng phổ biến trong chẩn đoán melanoma:

- **A – Asymmetry:** hình dạng vùng tổn thương không đối xứng, là dấu hiệu sớm của ung thư da.
- **B – Border:** ranh giới không đều, rách rời hoặc mờ nhạt.
- **C – Color:** sự thay đổi và phối hợp màu bất thường (từ đen, nâu, đỏ, trắng đến xanh).
- **D – Diameter:** kích thước lớn hơn 6mm – một cảnh báo nguy cơ cao.
- **E – Evolution:** sự tiến triển nhanh theo thời gian về kích thước, màu sắc hoặc hình dạng.

MBConv-512 cho phép mô hình không chỉ trích xuất mà còn hiểu được mối quan hệ giữa các đặc trưng toàn cục, tạo ra bức tranh tổng thể về nguy cơ ung thư. Tầng này đóng vai trò then chốt trong việc hỗ trợ ra quyết định phân loại giữa melanoma, basal cell carcinoma và các loại tổn thương da khác một cách chính xác và toàn diện.

Chuẩn hóa:

-Công thức:

$$x_{norm} = \frac{x - \mu}{\sigma}$$

Khi đưa các giá trị metadata (như tuổi, kích thước tổn thương, ...) về cùng thang đo, mục tiêu là chuẩn hóa các giá trị để chúng có thể được sử dụng hiệu quả trong mô hình học máy. Ví dụ, tuổi (từ 0-100) và kích thước tổn thương (từ vài mm đến vài cm) sẽ được chuyển đổi về phân phối chuẩn với trung bình 0 và độ lệch chuẩn 1. Quá trình chuẩn hóa này giúp các giá trị metadata có tầm ảnh hưởng đồng nhất và tránh gây ra sự thiên lệch do các đơn vị đo lường khác nhau, từ đó cải thiện hiệu quả của mô hình phân loại.

One-hot Encoding:

Khi chuyển đổi các thông tin như vị trí tổn thương, giới tính, v.v. thành dạng vector, mục tiêu là biến những dữ liệu phân loại thành các giá trị số có thể sử dụng trong mô hình học máy. Ví dụ, với thông tin vị trí tổn thương, ta có thể mã hóa các vùng như sau:

- Vị trí tổn thương: Mặt → [1, 0, 0, 0], Ngực → [0, 1, 0, 0], …
- Giới tính: Nam → [1, 0], Nữ → [0, 1]

Embedding:

- Công thức:

$$e = W_{meta} \cdot x_{norm}$$

Khi ánh xạ các đặc trưng metadata đã chuẩn hóa thành vector có chiều cố định, mô hình sẽ học được các mối quan hệ giữa các giá trị metadata và ảnh hưởng của chúng đến kết quả phân loại.

Và sau khi xử lý xong metadata thì ta sẽ luồng qua ViT để tiếp tục quá trình:

Patch Embedding

- Công thức:

$$z_0 = \left[x_{class}; x_p^1 E; x_p^2 E; \dots; x_p^N E\right] + E_{pos}$$

Khi chia ảnh ung thư da thành 196 patch 16×16, quá trình này phân tách ảnh 2D lớn thành các phần nhỏ, mỗi patch chứa một phần nhỏ của tổn thương. Mỗi patch sau đó được ánh xạ thành một vector 768 chiều, giúp mô hình nắm bắt các đặc điểm chi tiết của từng phần tổn thương. Thêm vào đó, token [CLS] đặc biệt được đưa vào đầu chuỗi các patch, đại diện cho thông tin tổng quát của toàn bộ ảnh. Việc này giúp mô hình hiểu được mối liên hệ giữa

các patch và đưa ra dự đoán chính xác hơn về tình trạng tổn thương. Quá trình này tác động lên ảnh ung thư da, biến đổi ảnh 2D thành chuỗi các patch, mỗi patch chứa thông tin quan trọng về tổn thương, hỗ trợ mô hình trong việc phân tích và nhận diện các đặc trưng ung thư.

Positional Encoding

- Công thức:

$$\boldsymbol{PE_{(pos,2i)} = sin(pos/1000^{2i/d_{model}})}$$

$$\boldsymbol{PE_{(pos,2i+1)} = cos(pos/1000^{2i/d_{model}})}$$

Khi thêm thông tin vị trí cho mỗi patch, quá trình này giúp mô hình hiểu được vị trí tương đối của các vùng tổn thương trong ảnh ung thư da. Việc này đặc biệt quan trọng vì vị trí của các tổn thương có thể mang lại thông tin quan trọng cho chẩn đoán. Ví dụ, sự phân bố sắc tố từ trung tâm ra ngoại vi của tổn thương có thể là một dấu hiệu của ung thư hắc tố. Mô hình sẽ sử dụng thông tin vị trí để phân tích cách các vùng tổn thương phân bố trên bề mặt da, từ đó hỗ trợ trong việc xác định các mẫu phân bố và mối liên hệ giữa các vùng tổn thương, góp phần nâng cao độ chính xác trong chẩn đoán ung thư da.

Multi-Head Self Attention

- Công thức:

$$\boldsymbol{Q = XW_Q, K = XW_K, V = XW_V}$$

$$\boldsymbol{Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V}$$

$$\boldsymbol{MultiHead(X) = Concat(head_1, \dots, head_h)W^O}$$

Khi tính toán mối quan hệ giữa mọi cặp patch trong ảnh ung thư da, quá trình này giúp mô hình so sánh và phân tích các vùng khác nhau trong tổn thương. Mối quan hệ giữa các patch cho phép mô hình phát hiện các mối tương quan không gian quan trọng, ví dụ như sự tương phản giữa trung tâm và ngoại vi của tổn thương. Những thông tin này có thể là dấu hiệu của các loại ung thư da, như ung thư hắc tố, nơi sự thay đổi sắc tố và cấu trúc có thể phân bổ không đều từ trung tâm ra ngoại vi. Ngoài ra, việc chú ý đến cấu trúc toàn cục,

như tính đối xứng hoặc bất đối xứng của tổn thương, giúp mô hình nhận diện các dấu hiệu bất thường quan trọng cho chẩn đoán chính xác.

MLP Feed Forward

- Công thức:

$$\boldsymbol{FFN(x) = GELU(xW_1 + b_1)W_2 + b_2}$$

Khi xử lý thông tin sau attention, quá trình này giúp tạo ra các đặc trưng phức tạp hơn sau khi đã phân tích các mối quan hệ không gian giữa các patch trong ảnh ung thư da. Việc này cho phép mô hình học được các đặc trưng phân biệt cấp cao, giúp nhận diện sự khác biệt giữa các loại ung thư da khác nhau. Các mối quan hệ không gian giữa các vùng tổn thương, như sự đối xứng/bất đối xứng, sự phân bố sắc tố, và các đặc điểm cấu trúc khác, sẽ được mô hình học hỏi và sử dụng để phân biệt các loại ung thư như ung thư hắc tố, ung thư tế bào đáy, tế bào vảy, và tổn thương lành tính. Kết quả là, mô hình có thể tạo ra các đặc trưng mạnh mẽ và chính xác để hỗ trợ chẩn đoán ung thư da.

Layer Normalization

- Công thức:

$$\boldsymbol{LN(x) = \gamma . \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta}$$

Khi chuẩn hóa giá trị của mỗi vector đặc trưng, quá trình này giúp đảm bảo rằng các đặc trưng được học trong mô hình diễn ra ổn định và không bị ảnh hưởng bởi các giá trị quá lớn hoặc quá nhỏ. Đặc biệt đối với ảnh ung thư da, nơi có sự đa dạng về màu sắc và độ tương phản, việc chuẩn hóa là rất quan trọng. Nó giúp các đặc trưng liên quan đến màu sắc, độ sáng tối và các chi tiết hình ảnh khác được xử lý đồng nhất, tránh gây thiên lệch trong quá trình huấn luyện. Bằng cách chuẩn hóa, mô hình có thể học các đặc trưng một cách chính xác và hiệu quả, đặc biệt khi các tổn thương có sự thay đổi sắc tố hoặc độ tương phản mạnh mẽ.

[CLS] Token và Classification Head

- Công thức:

$$\boldsymbol{y = W . x_{[CLS]} + b}$$

Khi sử dụng token [CLS] để tổng hợp thông tin từ toàn bộ ảnh ung thư da, token này sẽ chứa các đặc trưng quan trọng từ tất cả các patch trong ảnh, tạo thành một đại diện tổng quát cho tổn thương. Sau đó, classification head sẽ ánh xạ vector đặc trưng này sang không gian lớp, tức là sẽ chuyển đổi các đặc trưng tổng hợp thành các điểm số cho mỗi loại chẩn đoán. Cụ thể, đối với ảnh ung thư da, mô hình sẽ sử dụng thông tin từ token [CLS] để tổng hợp tất cả các đặc trưng quan trọng, từ màu sắc, vị trí, đến cấu trúc tổn thương. Dựa trên những đặc trưng này, mô hình sẽ đưa ra điểm số cho mỗi loại ung thư da, ví dụ như ung thư hắc tố, ung thư tế bào đáy, tế bào vảy, hoặc tổn thương lành tính, giúp bác sĩ đưa ra chẩn đoán cuối cùng chính xác.

Sau khi thực hiện đi qua tất cả các layer trong mô hình chúng tôi sẽ dùng phương pháp nối chuỗi concat để nối có đặc trưng lại với nhau:

-Công thức:

$$\boldsymbol{f}_{\boldsymbol{combined}} = [\boldsymbol{f}_{\boldsymbol{ResNet}}; \boldsymbol{f}_{\boldsymbol{ViT}}; \boldsymbol{f}_{\boldsymbol{meta}}]$$

Khi kết hợp các đặc trưng từ các nguồn khác nhau thành một vector đặc trưng lớn, quá trình này tạo ra một đại diện toàn diện hơn cho ảnh ung thư da. Cụ thể:

- **EfficientNet-B0**: Cung cấp các đặc trưng cục bộ như kết cấu và biên dạng của tổn thương, giúp mô hình nhận diện các chi tiết nhỏ như các vết nứt, vảy hoặc sự thay đổi cấu trúc của tổn thương.

- **ViT (Vision Transformer)**: Cung cấp các đặc trưng toàn cục, như mối tương quan không gian giữa các vùng khác nhau trong tổn thương và hình dạng tổng thể của tổn thương. Việc sử dụng ViT giúp mô hình hiểu được các yếu tố hình học và phân bố của tổn thương trên bề mặt da.

- **Metadata**: Tích hợp các đặc trưng ngữ cảnh lâm sàng như tuổi, vị trí và kích thước của tổn thương. Những thông tin này cung cấp cái nhìn sâu sắc về khả năng nguy cơ ung thư dựa trên đặc điểm của người bệnh và tổn thương, chẳng hạn như các tổn thương xuất hiện ở vùng da tiếp xúc nhiều với ánh nắng.

Cross-attention

Khi tạo mối liên hệ giữa các đặc trưng từ các nguồn khác nhau, mô hình có khả năng học cách tương tác giữa thông tin hình ảnh và metadata. Đối với ảnh ung thư da, điều này cho

phép mô hình "đặt câu hỏi" giữa các loại đặc trưng, ví dụ: sử dụng thông tin tuổi để điều chỉnh sự chú ý vào các đặc điểm hình ảnh phổ biến ở nhóm tuổi đó. Nhờ đó, mô hình có thể nhận diện tổn thương chính xác hơn bằng cách kết hợp ngữ cảnh lâm sàng với đặc trưng hình ảnh, chẳng hạn như tăng sự chú ý vào vùng có sắc tố bất thường ở người lớn tuổi hoặc cấu trúc không đối xứng ở các vị trí thường gặp ung thư. Việc tạo liên kết như vậy giúp mô hình đưa ra các phán đoán tinh tế và phù hợp hơn với từng trường hợp cụ thể.

CHƯƠNG 3: THỰC NGHIỆM VÀ ĐÁNH GIÁ

1. Quy trình huấn luyện và kiểm thử

Quy trình huấn luyện và kiểm thử mô hình Hybrid CNN-ViT được xây dựng theo các bước cụ thể sau:

Bước 1: Chuẩn bị dữ liệu

- Dữ liệu huấn luyện và kiểm thử gồm một phần bộ ISIC2024(bao gồm 29.868 ảnh, 393 ảnh ác tính và 29.475 ảnh lành tính được chọn ngẫu nhiên) và PAD-UFES-20, trong đó các ảnh có kích thước gốc khác nhau được resize về 224×224 pixel.
- Các đặc trưng metadata được xử lý qua bước tiền xử lý bao gồm: xử lý khuyết dữ liệu, chuẩn hóa theo bệnh nhân, và tạo thêm đặc trưng mới (feature engineering).
- Dữ liệu được chia thành các tập huấn luyện và kiểm thử theo k-fold cross-validation (mặc định K=3) với bảo toàn nhóm bệnh nhân (StratifiedGroupKFold).
- Tập dữ liệu ISIC2024 được chia thành:
    - 80% cho huấn luyện
    - 10% cho kiểm thử (validation)
    - 10% cho đánh giá (test)
- Tập PAD-UFES-20 được xử lí tương tự ISIC để giữ nhất quán pipeline, bao gồm resize, chuyển đổi sang tensor và augmentation.

Bước 2: Tăng cường và cân bằng dữ liệu

- Trong huấn luyện ảnh: sử dụng các kỹ thuật tăng cường dữ liệu (augmentation) như lật ảnh, xoay, thay đổi độ sáng, blur, erasing,… nhằm tránh overfitting và tăng tính đa dạng dữ liệu.
- Trong huấn luyện metadata: tùy chọn sử dụng kỹ thuật SMOTE để cân bằng lại số lượng mẫu giữa lớp lành tính và ác tính.
- Riêng tập PAD-UFES-20 vì đã cân bằng sẵn, nên không cần sử dụng kỹ thuật SMOTE, mà huấn luyện luôn trên tập dữ liệu thuần.

Bước 3: Cấu hình mô hình

- Mô hình Hybrid CNN-ViT gồm hai nhánh xử lý ảnh song song:

  - Nhánh CNN sử dụng EfficientNet-B0 (đã pretrained), trích xuất đặc trưng cục bộ.
  - Nhánh ViT sử dụng kiến trúc ViT-B/16 (pretrained), học quan hệ toàn cục trong ảnh.
- Các đặc trưng từ hai nhánh được đưa qua các lớp projection (512 chiều), sau đó kết hợp bằng cơ chế attention (gating) để trộn trọng số hai nhánh.
- Đầu ra là kết quả phân loại (binary), có thể kèm các nhánh auxiliary output cho ViT và CNN để hỗ trợ huấn luyện.

Bước 4: Cấu hình huấn luyện

- Mô hình được huấn luyện bằng AdamW optimizer với learning rate 5e-5 và weight decay 1e-5.
- Hàm mất mát chính là BCEWithLogitsLoss, có thêm hệ số phụ từ 2 nhánh auxiliary.
- Sử dụng scheduler OneCycleLR để điều chỉnh tốc độ học và gradient clipping (norm ≤ 1.0) để ổn định quá trình huấn luyện.
- Huấn luyện dừng sớm nếu AUC trên tập validation không cải thiện sau 4 epoch liên tiếp (early stopping).

Bước 5: Đánh giá mô hình

1. Chỉ số đánh giá chính

- **ROC AUC**: Đánh giá khả năng phân biệt hai lớp trên toàn bộ miền FPR.
- **Partial AUC (pAUC)**: Bao gồm cả raw và normalized pAUC tại ngưỡng FPR ≤ 0.20: phản ánh hiệu năng tổng quát ở mức cảnh báo thấp.
- **Classification Report**: Báo cáo precision, recall và F1-score cho từng lớp, chỉ đặc biệt áp dụng riêng cho tập PAD đã cân bằng.

2. Chiến lược đánh giá theo từng bộ dữ liệu

- **Đối với ISIC 2024**:
  - Đây là tập dữ liệu mất cân bằng nghiêm trọng, nên mô hình được đánh giá ở hai điều kiện riêng biệt:

        - Trước khi áp dụng SMOTE: phản ánh hiệu năng nguyên thủy khi mất cân bằng lớp còn tồn tại.
        - Sau khi áp dụng SMOTE: kiểm tra mức cải thiện khi sử dụng kỹ thuật cân bằng dữ liệu.
    - Các chỉ số ROC AUC và pAUC là trọng tâm để đánh giá sự thay đổi hiệu quả giữa hai điều kiện.
    - Việc tách dữ liệu được thực hiện theo Stratified Group K-Fold để tránh trùng lặp bệnh nhân.
- **Đối với PAD-UFES-20**:
    - Đây là tập dữ liệu đã cân bằng giữa hai lớp, nên SMOTE không cần thiết.
    - Mô hình được đánh giá trực tiếp qua classification report và ROC AUC để kiểm tra khả năng phân loại từng lớp một cách chi tiết.

3. So sánh mô hình và kết hợp metadata

- Mô hình Hybrid là giải pháp chính trong nghiên cứu.
- Hai mô hình đơn lẻ ViT và CNN được sử dụng như mốc đối chứng (baseline) để đánh giá mức độ cải thiện của Hybrid.
- Ngoài mô hình ảnh, nghiên cứu còn tích hợp thêm metadata (tuổi, giới tính, vị trí tổn thương, v.v.) bằng các mô hình học máy như LightGBM và XGBoost, sau đó kết hợp với mô hình ảnh thông qua ensemble (học cuối - late fusion) nhằm khai thác thông tin đa chiều và nâng cao độ chính xác tổng thể.

2. Kết quả và phân tích:

2.1 Kết quả trên bộ dữ liệu ISIC 2024:

Để đánh giá tác động của kỹ thuật cân bằng dữ liệu SMOTE cũng như so sánh hiệu quả giữa các mô hình, các thí nghiệm được tiến hành độc lập trên bộ dữ liệu ISIC 2024 với hai kịch bản:

- Trường hợp 1: Dữ liệu gốc, chưa áp dụng SMOTE.
- Trường hợp 2: Dữ liệu sau khi áp dụng SMOTE để tăng cường lớp thiểu số.

Trọng tâm của phân tích là mô hình Hybrid (EfficientNet-B0 + ViT), mô hình chính của nghiên cứu. Các hình và bảng dưới đây minh họa đường cong ROC và giá trị AUC, pAUC của Hybrid trong hai điều kiện trước và sau khi sử dụng SMOTE:

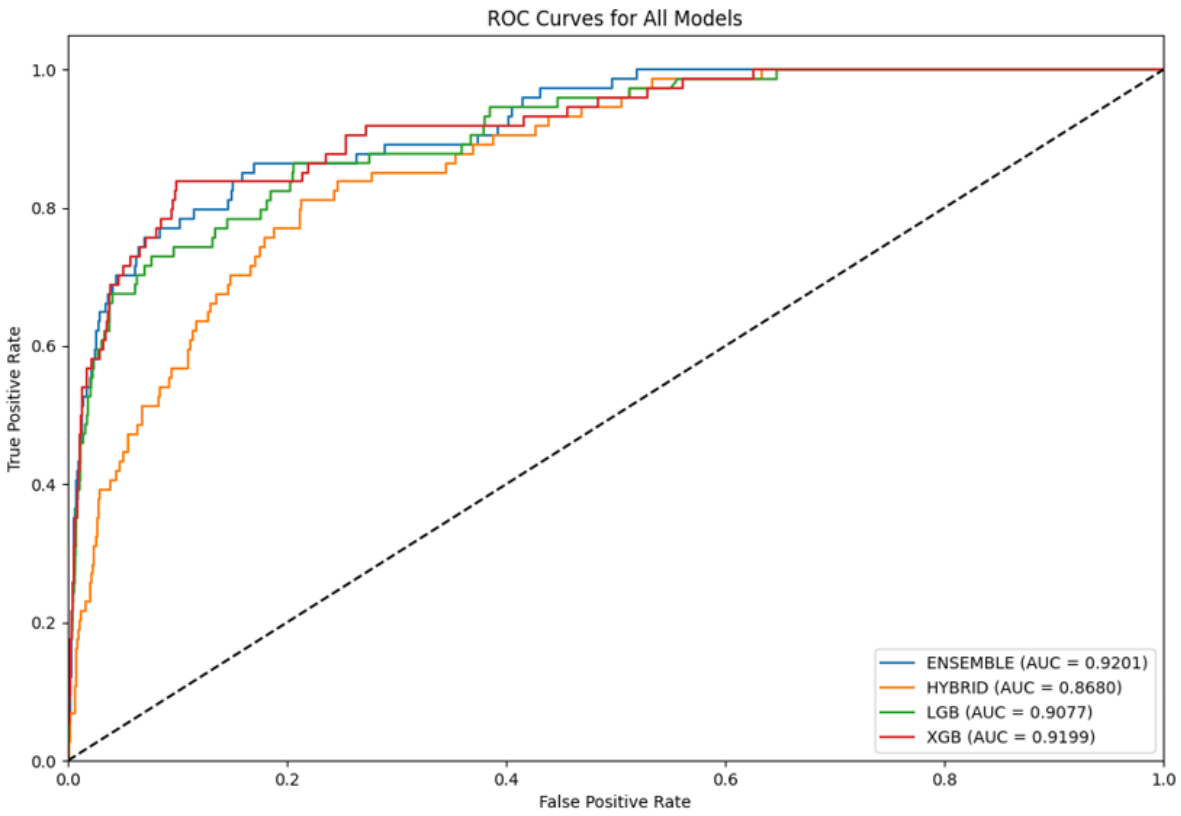

Hình 2 ROC Curve & AUC của Hybrid trước SMOTE

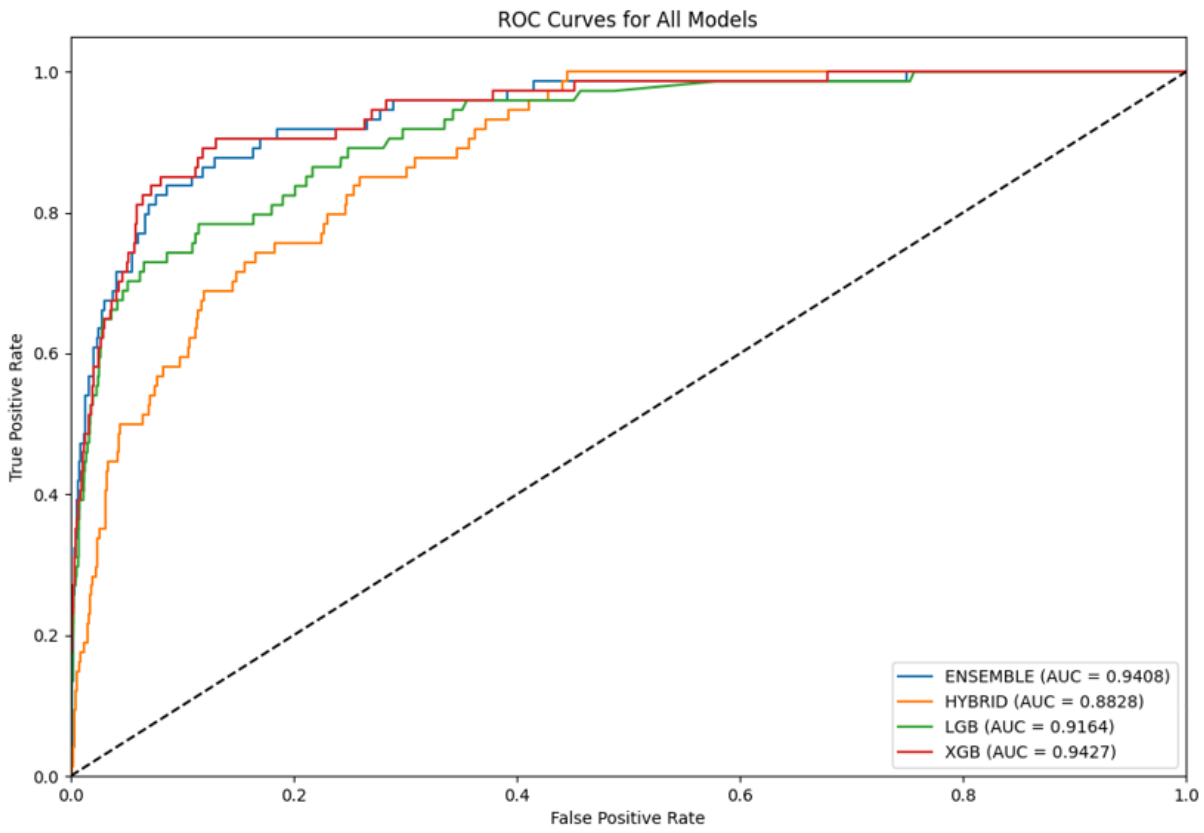

Hình 3 ROC Curve & AUC của Hybrid sau SMOTE

Mô hình	ROC AUC	Raw pAUC (0–20%)	Norm pAUC (0–20%)
Hybrid(no SMOTE)	0.9201	0.1212	0.6062
Hybrid(SMOTE)	**0.9408**	**0.1427**	**0.7136**

Bảng 1 Chỉ số chi tiết của mô hình Hybrid trước và sau khi áp dụng SMOTE

Phân tích chi tiết các chỉ số:

- **ROC AUC (Area Under the Receiver Operating Characteristic Curve):**
  - Mô hình Hybrid(SMOTE) đạt điểm ROC AUC cao hơn (0.9408) so với mô hình Hybrid(no SMOTE) (0.9201).
  - Điều này cho thấy mô hình sử dụng SMOTE có khả năng phân biệt tổng thể giữa các lớp tốt hơn trên tất cả các ngưỡng quyết định.

- **Raw pAUC (0–20%) và Norm pAUC (0–20%):**
    - Raw pAUC (0–20%): Mô hình Hybrid(SMOTE) (0.1427) tiếp tục cho thấy hiệu suất cao hơn so với Hybrid(no SMOTE) (0.1212).
    - Norm pAUC (0–20%): Tương tự, Hybrid(SMOTE) (0.7138) vượt trội hơn Hybrid(no SMOTE) (0.6062).

Nhận xét và Kết luận:

Khác với phân tích dựa trên bảng dữ liệu ban đầu (bị nhầm lẫn), bảng dữ liệu chính xác này cho thấy kỹ thuật SMOTE đã cải thiện hiệu suất của mô hình Hybrid trên tất cả các chỉ số được đánh giá.

SMOTE không chỉ nâng cao khả năng phân loại tổng thể (ROC AUC) mà còn cải thiện hiệu suất trong các vùng có tỷ lệ dương tính giả thấp (cả Raw pAUC và Norm pAUC ở khoảng 0-20%).

Kết quả này cho thấy việc áp dụng SMOTE trong trường hợp này đã thành công trong việc giải quyết vấn đề mất cân bằng dữ liệu (nếu có) mà không làm suy giảm hiệu suất ở các ngưỡng quyết định quan trọng. Việc mô hình Hybrid(SMOTE) tốt hơn ở cả pAUC cho thấy nó có khả năng nhận diện lớp thiểu số tốt hơn mà không làm tăng đáng kể số lượng cảnh báo sai ở các mức ưu tiên cao.

So sánh cùng các mô hình đơn lẻ đối chứng CNN và ViT:

Mô hình	SMOTE	ROC AUC	Raw pAUC (0–20%)	Norm pAUC (0–20%)
Hybrid	Có	**0.9408**	**0.1427**	**0.7136**
	Không	0.9201	0.1212	0.6062
ViT	Có	0.9405	0.1403	0.7013
	Không	0.9221	0.1219	0.6096
CNN	Có	0.9311	0.1418	0.7090
	Không	0.9100	0.1091	0.5456

Bảng 2 Chỉ số của mô hình Hybrid và các mô hình đối chứng trước và sau SMOTE

a. Hiệu năng tổng thể (ROC AUC)

- Hybrid đạt ROC AUC cao nhất (0.9408) khi áp dụng SMOTE, vượt nhẹ ViT (0.9405) và đáng kể hơn so với CNN (0.9311).
- Ngay cả khi không sử dụng SMOTE, Hybrid vẫn giữ mức hiệu năng khá cao (0.9201), chỉ thấp hơn ViT (0.9221) một cách không đáng kể, nhưng vẫn vượt CNN (0.9100).
- Điều này cho thấy Hybrid có khả năng tổng quát hóa mạnh và ít bị ảnh hưởng bởi sự mất cân bằng dữ liệu hơn.

b. Phân tích pAUC ở vùng FPR 0–20%:

- Ở raw pAUC(0-20%), khi có SMOTE Hybrid thể hiện rõ sự vượt trội với raw pAUC lên đến 0.1427, vượt xa ViT và CNN với chỉ số lần lượt là 1403 và 1418
- Hybrid tiếp tục dẫn đầu ở normalized pAUC (0–20%) sau khi dùng SMOTE (0.7136), vượt cả ViT (0.7013) và CNN (0.7090).
- Điều này cho thấy Hybrid không chỉ giỏi ở độ nhạy cao mà còn giữ vững độ đặc hiệu, phù hợp cho hệ thống hỗ trợ ra quyết định lâm sàng.
- Khi không dùng SMOTE, Hybrid vẫn nhỉnh hơn CNN ở chỉ số này(0.6062>0.5456) và chỉ kém hơn 1 chút so với ViT(0.6062<0.6096).

2.2 Kết quả trên bộ dữ liệu PAD-UFES-20:

Khác với ISIC, bộ dữ liệu PAD-UFES-20 có sự cân bằng tốt giữa hai lớp (lành tính và ác tính). Vì vậy, trong quá trình huấn luyện trên PAD, kỹ thuật SMOTE không được áp dụng, và mô hình được đánh giá trực tiếp dựa trên các chỉ số phân loại chuẩn.

Kết quả chi tiết được trình bày trong bảng dưới đây:

Mô hình	Lớp	Precision	Recall	F1-score	Ghi chú chính
Hybrid	0 (lành tính)	0.9444	0.5484	0.6939	Precision rất cao, nhưng recall thấp
	1 (ác tính)	0.6387	0.9612	0.7674	Recall cực cao, ưu tiên phát hiện ca ác
ViT	0	0.7338	0.9113	0.8129	Phát hiện ca lành rất tốt

	1	0.8493	0.6019	0.7045	Precision cao, recall thấp ở lớp ác
CNN	0	0.7724	0.9032	0.8327	Toàn diện ở lớp lành
	1	0.8537	0.6796	0.7568	Precision cao nhất ở lớp ác

Bảng 3 Chỉ số class report của các mô hình trên tập PAD, kèm đánh giá cơ bản

Nhận xét theo từng lớp

Lớp 0 (Lành tính):

- Hybrid đạt precision rất cao (0.9444) nhưng recall thấp nhất (0.5484) đối với lớp lành tính, cho thấy mô hình dễ nhận nhầm ca lành thành ca bệnh (dương tính giả).
- ViT và CNN cân bằng hơn, đặc biệt ViT đạt recall cao nhất (0.9113) ở lớp này.

Lớp 1 (Ác tính):

- Hybrid có recall vượt trội (0.9612), cao nhất trong tất cả mô hình, cho thấy khả năng phát hiện tổn thương ác tính cực kỳ tốt.
- F1-score lớp ác của Hybrid cũng cao nhất (0.7674), mặc dù precision chỉ ở mức khá (0.6387).
- Ngược lại, ViT và CNN có precision cao hơn nhưng recall thấp hơn, dẫn đến nguy cơ bỏ sót những ca ung thư (âm tính giả), điều này đặc biệt nguy hiểm trong chẩn đoán y tế.

3. Tổng kết:

Qua các kết quả thực nghiệm, các mô hình học sâu được huấn luyện và đánh giá độc lập trên hai bộ dữ liệu ISIC 2024 và PAD-UFES-20, nhằm kiểm chứng hiệu quả của mô hình chính Hybrid (EfficientNet-B0 + ViT) so với các mô hình nền tảng ViT và CNN.

Trên tập ISIC 2024, vốn mang tính mất cân bằng dữ liệu cao, mô hình Hybrid cho thấy hiệu quả nổi bật về ROC AUC và normalized pAUC, đặc biệt sau khi áp dụng SMOTE, Hybrid đã thể hiện hiệu năng ổn định hơn trên toàn phổ FPR ở ngưỡng 0-20%, cho thấy mô hình có khả năng duy trì hiệu quả cao trong môi trường có tỉ lệ dương tính giả thấp, phù hợp với yêu cầu thận trọng trong chẩn đoán y khoa.

Trên tập PAD-UFES-20, nơi dữ liệu đã cân bằng, Hybrid vẫn giữ hiệu suất cao và có recall vượt trội ở lớp ác tính (96.12%), điều quan trọng nhất trong bối cảnh sàng lọc ung thư da.

Mặc dù ViT và CNN có F1-score cao hơn ở lớp lành tính, nhưng recall thấp hơn ở lớp ác tính, làm tăng nguy cơ bỏ sót tổn thương nguy hiểm. Điều này cho thấy Hybrid là mô hình phù hợp hơn với định hướng ưu tiên an toàn cho bệnh nhân.

Ngoài ra, việc kết hợp mô hình Hybrid với các mô hình xử lý metadata (LightGBM, XGBoost) thông qua cơ chế ensemble cũng góp phần cải thiện độ chính xác tổng thể, mở ra hướng tiếp cận tích hợp giữa dữ liệu ảnh và dữ liệu lâm sàng.

Tổng thể, kết quả thực nghiệm đã chứng minh rằng mô hình Hybrid không chỉ đạt hiệu năng cạnh tranh, mà còn phù hợp hơn với các tiêu chí đánh giá đặc thù trong y học, đặc biệt là trong việc giảm thiểu nguy cơ bỏ sót tổn thương ác tính, từ đó khẳng định tính khả thi và giá trị ứng dụng thực tiễn của mô hình trong hỗ trợ chẩn đoán bệnh lý da.

KẾT LUẬN VÀ KIẾN NGHỊ

I. KẾT LUẬN:

Thông qua quá trình nghiên cứu và thực nghiệm được trình bày, mô hình Hybrid CNN-ViT kết hợp giữa CNN(EfficientNet-B0) và Vision Transformer đã chứng minh được vai trò trung tâm và tính hiệu quả vượt trội trong bài toán phân loại tổn thương da lành tính và ác tính từ hình ảnh. Mô hình không chỉ đạt hiệu năng cao trên phương diện kỹ thuật thông qua các chỉ số ROC AUC và pAUC, mà còn thể hiện rõ sự phù hợp với các tiêu chí đặc thù trong lĩnh vực y học, đặc biệt là trong bối cảnh ứng dụng vào hệ thống hỗ trợ chẩn đoán sớm ung thư da. Khi so sánh với các mô hình đối chứng như CNN và ViT đơn lẻ, Hybrid cho thấy mức độ ổn định và linh hoạt cao hơn rõ rệt, đồng thời khắc phục được những hạn chế riêng lẻ của từng kiến trúc: CNN thường bị giới hạn trong khả năng học đặc trưng toàn cục, còn ViT dù mạnh ở global attention nhưng thiếu đi tính cục bộ – sự kết hợp của cả hai trong Hybrid đã tạo nên một mô hình cân bằng hơn về mặt biểu diễn đặc trưng.

Một trong những thách thức lớn trong bài toán phân loại tổn thương da là mất cân bằng dữ liệu, khi số lượng mẫu của lớp ác tính thường ít hơn nhiều so với lớp lành tính. Điều này có thể khiến mô hình thiên về dự đoán lớp chiếm đa số, dẫn đến giảm độ nhạy và hiệu quả trong việc phát hiện các ca bệnh nguy hiểm. Để khắc phục vấn đề này, nghiên cứu đã áp dụng kỹ thuật SMOTE (Synthetic Minority Over-sampling Technique) nhằm tăng cường mẫu cho lớp thiểu số bằng cách tạo ra các mẫu giả tổng hợp từ dữ liệu gốc. Việc này giúp cân bằng lại phân bố dữ liệu, cải thiện khả năng học của mô hình trên các trường hợp hiếm gặp, đồng thời nâng cao hiệu quả dự đoán, đặc biệt ở vùng FPR thấp rất quan trọng trong y học để đảm bảo tính nhạy bén và giảm thiểu khả năng bỏ sót ca bệnh ác tính. Kết quả thực nghiệm đã chứng minh SMOTE góp phần tăng rõ rệt chỉ số ROC AUC và pAUC, giúp mô hình Hybrid CNN-ViT có khả năng phân loại ổn định và chính xác hơn trong môi trường dữ liệu mất cân bằng thực tế.

Đặc biệt, việc đánh giá mô hình trên hai bộ dữ liệu có đặc điểm khác biệt – ISIC 2024 (mất cân bằng) và PAD-UFES-20 (đã cân bằng) – cho thấy tính tổng quát hóa tốt của Hybrid. Trên tập ISIC 2024, nghiên cứu đã tiến hành thực nghiệm ở cả hai điều kiện: trước và sau

khi áp dụng kỹ thuật cân bằng dữ liệu SMOTE. Kết quả cho thấy rõ ràng rằng SMOTE đóng vai trò quan trọng trong việc cải thiện hiệu năng mô hình, đặc biệt ở vùng FPR thấp, nơi phản ánh độ nhạy và tính cảnh báo sớm. Sau khi áp dụng SMOTE, mô hình Hybrid đạt ROC AUC cao nhất (0.9408) cùng normalized pAUC (0–20%) vượt trội, cho thấy khả năng phân loại ổn định trên toàn phổ độ đặc hiệu. Trong khi đó, khi không áp dụng SMOTE, Hybrid vẫn giữ được mức hiệu suất tốt và không sụt giảm nghiêm trọng như mô hình CNN, chứng minh khả năng thích nghi tốt với dữ liệu mất cân bằng.

Trên tập dữ liệu PAD-UFES-20 – nơi hai lớp được phân bố tương đối đồng đều – mô hình Hybrid tiếp tục phát huy thế mạnh, đặc biệt ở lớp ác tính. Với recall đạt tới 96.12% ở lớp tổn thương ác tính, Hybrid khẳng định định hướng rõ ràng là ưu tiên phát hiện đúng các ca nguy cơ, dù điều đó có thể đồng nghĩa với việc chấp nhận một tỷ lệ cảnh báo giả cao hơn ở lớp lành tính. Điều này hoàn toàn phù hợp với bối cảnh ứng dụng y học, nơi việc bỏ sót ca bệnh nguy hiểm có thể gây hậu quả nghiêm trọng hơn nhiều so với cảnh báo nhầm. Chính sự khác biệt này khiến Hybrid, dù có thể không luôn dẫn đầu về các chỉ số trung bình như macro F1 hay weighted F1, vẫn là mô hình phù hợp nhất với yêu cầu thực tiễn trong sàng lọc và chẩn đoán lâm sàng, bởi vì nó đặt sự an toàn và tính mạng người bệnh lên hàng đầu.

Ngoài ra, khi được tích hợp thêm thông tin metadata qua các mô hình học máy như LightGBM và XGBoost trong cơ chế ensemble, Hybrid tiếp tục thể hiện sự linh hoạt trong việc xử lý đa dạng nguồn dữ liệu, từ đó cải thiện thêm độ chính xác tổng thể. Điều này mở ra hướng tiếp cận đa kênh (multi-modal) trong y học, nơi ảnh và thông tin lâm sàng cùng được đưa vào phân tích nhằm đưa ra kết luận chính xác và đáng tin cậy hơn.

Tổng hợp lại, mô hình Hybrid không chỉ hoàn thành mục tiêu kỹ thuật đặt ra trong nghiên cứu mà còn đáp ứng đúng tinh thần của các ứng dụng y tế hiện đại: chính xác, an toàn, có khả năng tổng quát hóa, và sẵn sàng ứng dụng thực tiễn. Với khả năng phát hiện ca nguy hiểm tốt hơn, hiệu năng ổn định trước các thách thức như mất cân bằng lớp, cùng tính thích nghi với dữ liệu đa dạng, Hybrid khẳng định giá trị thực tiễn cao và tiềm năng ứng dụng trong hệ thống hỗ trợ chẩn đoán hình ảnh y học, đặc biệt là trong phát hiện sớm và sàng lọc tổn thương da nghi ngờ ác tính.

II. KIẾN NGHỊ:

Dựa trên kết quả nghiên cứu và thực nghiệm, mô hình Hybrid CNN-ViT đã cho thấy tiềm năng lớn trong việc hỗ trợ phân loại tổn thương da lành tính và ác tính với hiệu suất cao và độ ổn định đáng kể. Tuy nhiên, để đáp ứng yêu cầu thực tiễn trong lĩnh vực y học và triển khai rộng rãi trong các hệ thống chẩn đoán sớm, một số hướng phát triển và cải tiến là cần thiết.

Trước hết, vấn đề mất cân bằng dữ liệu vẫn là một thách thức quan trọng cần được xử lý hiệu quả hơn. Kỹ thuật SMOTE tuy đã cải thiện đáng kể khả năng nhận diện lớp thiểu số nhưng vẫn tồn tại hạn chế về mặt tính tự nhiên và đa dạng của dữ liệu tổng hợp. Do đó, nhóm nghiên cứu kiến nghị thay thế SMOTE bằng các phương pháp tổng hợp dữ liệu tiên tiến hơn như Generative Adversarial Networks (GANs), giúp tạo ra các mẫu dữ liệu có tính thực tiễn cao, từ đó nâng cao độ chính xác và tính tổng quát của mô hình.

Về mặt kiến trúc mô hình, để đạt hiệu quả tối ưu hơn, nhóm sẽ tập trung ứng dụng Neural Architecture Search (NAS) để tự động hóa quá trình thiết kế và tối ưu kiến trúc Hybrid CNN-ViT. Việc này giúp khám phá những cấu trúc mạng phù hợp nhất với đặc điểm dữ liệu tổn thương da, đồng thời cân bằng tốt giữa độ phức tạp mô hình và hiệu năng dự đoán.

Song song với đó, nhằm mở rộng khả năng ứng dụng trong thực tế, đặc biệt là tiếp cận người dùng cuối, nhóm nghiên cứu đề xuất phát triển phiên bản mô hình tối ưu cho nền tảng di động. Bằng cách áp dụng các kỹ thuật như model compression và quantization, mô hình sẽ được giảm kích thước và tăng tốc độ suy luận, đảm bảo có thể vận hành hiệu quả trên các thiết bị có tài nguyên hạn chế như smartphone hoặc thiết bị đeo thông minh. Điều này tạo điều kiện cho người dùng thực hiện kiểm tra tổn thương da ngay tại nhà, giúp phát hiện sớm các dấu hiệu ung thư da và mở rộng khả năng tiếp cận chẩn đoán ở các khu vực khó khăn về mặt y tế.

Ngoài ra, nhóm cũng kiến nghị tiếp tục phát triển hướng tiếp cận đa kênh (multi-modal) bằng cách kết hợp sâu hơn giữa hình ảnh tổn thương và các dữ liệu metadata lâm sàng thông qua các mô hình học máy ensemble như LightGBM, XGBoost hoặc các kỹ thuật học

sâu khác. Việc này sẽ góp phần nâng cao độ chính xác và độ tin cậy trong chẩn đoán, đồng thời cung cấp một công cụ hỗ trợ đa chiều cho bác sĩ trong quá trình ra quyết định.

Cuối cùng, nhóm đề xuất tăng cường hợp tác với các cơ sở y tế để thu thập thêm dữ liệu thực tế đa dạng, thực hiện các thử nghiệm lâm sàng quy mô lớn nhằm đánh giá hiệu quả và độ tin cậy của mô hình trong môi trường thực tế, từ đó hoàn thiện giải pháp trước khi ứng dụng rộng rãi.

TÀI LIỆU THAM KHẢO

Aburass, S., Dorgham, O., Al Shaqsi, J., Abu Rumman, M., & Al-Kadi, O. (2025). Vision transformers in medical imaging: A comprehensive review of advancements and applications across multiple diseases. *Journal of Imaging Informatics in Medicine*, 1–44.

Al-Asadi, M., & Altun, A. A. (2022). Deep learning with SMOTE techniques for improved skin lesion classification on unbalanced data. *Selcuk University Journal of Engineering Sciences*, 21(3), 97–104.

Brinker, T. J., Hekler, A., Enk, A. H., Klode, J., Hauschild, A., Berking, C., Schilling, B., Haferkamp, S., Schadendorf, D., Holland-Letz, T., Utikal, J. S., & Von Kalle, C. (2019). Deep learning outperformed 136 of 157 dermatologists in a head-to-head dermoscopic melanoma image classification task. *European Journal of Cancer*, 113, 47–54.

Brinker, T. J., Hekler, A., Utikal, J. S., Grabe, N., Schadendorf, D., Klode, J., Berking, C., Steeb, T., Enk, A. H., & Von Kalle, C. (2018). Skin cancer classification using convolutional neural networks: Systematic review. *Journal of Medical Internet Research*, 20(10), e11936.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794).

Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778).

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems* (pp. 3146–3154).

Kurtansky, R. V., Zaengle-Barone, J., Wang, J. V., Alam, M., & Cheng, C. E. (2024). The SLICE-3D dataset: 400,000 skin lesion image crops extracted from 3D TBP for skin cancer detection. *Scientific Data*, 11(1), 884.

Nguyen, V. D., Bui, N. D., & Do, H. K. (2022). Skin lesion classification on imbalanced data using deep learning with soft attention. *Sensors*, 22(19), 7530.

Nie, Y., Sommella, P., Carratù, M., O'Nils, M., & Lundgren, J. (2022). A deep CNN transformer hybrid model for skin lesion classification of dermoscopic images using focal loss. *Diagnostics*, 13(1), 72.

Ou, C., Zhou, S., Yang, R., Jiang, W., He, H., Gan, W., Chen, W., Qin, X., Luo, W., Pi, X., & Li, J. (2022). A deep learning based multimodal fusion model for skin lesion diagnosis using smartphone collected clinical images and metadata. *Frontiers in Surgery*, 9, 1029991.

Pacheco, A. G., Lima, G. R., de Souza, R. M. C. R., Lima, L. M. M., Neves, L. A., & de Oliveira, R. B. (2020). PAD-UFES-20: A skin lesion dataset composed of patient data and clinical images collected from smartphones. *Data in Brief*, 32, 106221.

Shahriar Himel, G. M., Islam, M. M., Al-Aff, K. A., Karim, S. I., & Sikder, M. K. U. (2024). Skin cancer segmentation and classification using vision transformer for automatic analysis in dermatoscopy-based non-invasive digital system. *arXiv preprint arXiv:2401.04746*.

Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., & Wojna, Z. (2016). Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 2818–2826).

Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning* (pp. 6105–6114). PMLR.

Tschandl, P., Rosendahl, C., & Kittler, H. (2018). The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions. *Scientific Data*, 5, 180161.

Yang, Z., Zhu, H., Zhang, R., Xie, D., Lin, H., & Zhang, Y. (2025). Embedding radiomics into vision transformers for multimodal medical image classification. *arXiv preprint arXiv:2504.10916*.

Zhao, M., Zhang, Y., Li, T., Wang, H., & Xie, X. (2023). Addressing class imbalance in skin lesion classification with dynamic multi-output convolutional neural network. *SSRN*.

PHỤ LỤC

Phụ lục A: Danh sách mô hình học sâu đã sử dụng trong nghiên cứu:

Tên mô hình	Mô tả
Vision Transformer (ViT)	Mô hình transformer áp dụng cho ảnh, học ngữ cảnh toàn cục thông qua cơ chế tự chú ý (self-attention).
Hybrid CNN-ViT	Kiến trúc lai giữa CNN EfficientNet-B0 (trích đặc trưng cục bộ) và ViT (ngữ cảnh toàn cục) cùng với phân loại bằng cây tăng cường như XGBoost hoặc LightGBM..
EfficientNet-B0	Mô hình CNN được thiết kế bằng kỹ thuật Neural Architecture Search (NAS), tối ưu hóa đồng thời về chiều sâu, chiều rộng và độ phân giải đầu vào.

Phụ lục B: Thông tin các bộ dữ liệu sử dụng:

Tên bộ dữ liệu	Nguồn gốc	Số lượng ảnh	Mô tả
ISIC 2024	International Skin Imaging Collaboration	~400.000	Bộ dữ liệu lớn và chuẩn hóa, gồm nhiều loại tổn thương da khác nhau.

PAD-UFES-20	UFES, Brazil	~2.300	Dữ liệu chụp bằng điện thoại thông minh, có đi kèm thông tin bệnh nhân.

Phụ lục C: Cấu hình và thông số huấn luyện mô hình:

Tham số	Giá trị thiết lập
Trình tối ưu hóa	AdamW
Tốc độ học	0.0001
Kích thước batch	32
Số epoch	20
Kỹ thuật cân bằng dữ liệu	SMOTE và các kỹ thuật tăng cường dữ liệu
Thư viện xử lý ảnh	Albumentations
Môi trường huấn luyện	PyTorch 2.x, CUDA 11.x

HUTECH
Đại học Công nghệ Tp.HCM

Tuần lễ	Ngày	Nội dung	Nhận xét của GVHD (Ký tên)
8	05/05/2025	- Tiến hành chạy thực nghiệm toàn bộ pipeline trên tập test. - Tổng hợp kết quả các mô hình (CNN, ViT, ensemble): Accuracy, Precision, Recall, F1, ROC-AUC. - Đánh giá ưu – nhược điểm giữa từng mô hình. - Lựa chọn mô hình tối ưu để trình bày trong báo cáo.	
9	12/05/2025	- Viết báo cáo kết quả thực nghiệm. - Trình bày chi tiết quy trình tiền xử lý, huấn luyện, đánh giá mô hình. - Trích xuất biểu đồ ROC, confusion matrix minh họa kết quả. - Kiểm tra lại tính nhất quán giữa nội dung báo cáo và tiến độ đã thực hiện.	
10	19/05/2025	- Hoàn thiện báo cáo đồ án: nội dung, hình ảnh minh họa, phân tích kết quả.	

Giảng viên hướng dẫn phụ (nếu có)
(Ký và ghi rõ họ tên)

TP. HCM, ngày 21 tháng 5 năm 2025
Giảng viên hướng dẫn chính
(Ký và ghi rõ họ tên)

HUTECH
Đại học Công nghệ Tp.HCM

Tuần lễ	Ngày	Nội dung	Nhận xét của GVHD *(Ký tên)*
3	30/03/2025	- Hoàn tất chuẩn hóa kích thước ảnh. -Cân bằng với SMOTE - Huấn luyện CNN (ResNet, EfficientNet), ViT (Swin), thử nghiệm ensemble.	
4	07/04/2025	- Huấn luyện mô hình kết hợp ViT và CNN. - Đánh giá sơ bộ trên validation set. - ViT+CNN kết hợp oversampling cho kết quả tốt nhất hiện tại.	
5	14/04/2025	- Phân tích hiệu suất từng lớp, đặc biệt lớp hiếm. - Áp dụng Focal Loss để cải thiện phân loại mất cân bằng. - Sử dụng thêm kỹ thuật augmentation để tăng tính đa dạng dữ liệu.	
6	21/04/2025	- Huấn luyện tiếp ViT + CNN trên tập dữ liệu mở rộng. - Oversampling + ViT + CNN vẫn cho kết quả tốt nhất. - Bắt đầu tinh chỉnh hyperparameter (learning rate, batch size...). Đánh giá công việc hoàn thành: ..... % Được tiếp tục: ☐ Không tiếp tục: ☐	
7	28/04/2025	- Thử nghiệm mô hình ensemble (vote từ ViT, CNN, EfficientNet). - Đánh giá cải thiện độ chính xác và độ ổn định.	

HUTECH
Đại học Công nghệ Tp.HCM

Khoa: Công nghệ Thông tin

PHIẾU THEO DÕI TIẾN ĐỘ

THỰC HIỆN ĐỒ ÁN CƠ SỞ

1. **Tên đề tài**: Nhận Diện Ung Thư Da Bằng Học Sâu
2. **Giảng viên hướng dẫn**: Bùi Danh Hường
3. **Sinh viên/ nhóm sinh viên thực hiện đề tài**:

(1) Nguyễn Quốc Vương MSSV: 2280603770 Lớp: 22DTHD3

(2) Ngô Hoàng Gia Bảo MSSV: 2280600198 Lớp: 22DTHD3

(3) Huỳnh Minh Quân MSSV: 2280602576 Lớp: 22DTHD3

Ngành: Công Nghệ Thông Tin

Chuyên ngành: Máy học và ứng dụng

Tuần lễ	Ngày	Nội dung	Nhận xét của GVHD *(Ký tên)*
1	14/03/2025	- Chọn đề tài nhận diện ung thư da bằng học sâu. - Lập kế hoạch sử dụng các bộ dữ liệu: ISIC, PAD-UFES-20. - Phương pháp: tiền xử lý, sử dụng SMOTE, xây mô hình, đánh giá.	
2	23/03/2025	- Tiền xử lý dữ liệu: chuẩn hóa, chia tập train/val/test. - Cân bằng dữ liệu bằng SMOTE - Thử nghiệm mô hình CNN đơn giản và ViT. - Đánh giá sơ bộ: độ chính xác, độ nhạy, độ đặc hiệu.	